

BENEVENTE: UM ARTEFATO AUDITÁVEL PARA DECISÕES DE CARTEIRA POR PERFIL DE INVESTIDOR

Diego Gallina

Pesquisador, Fucape Business School, Vitória, ES, Brasil, diego@wisearch.com

Resumo

Decisões de carteira precisam permanecer explicáveis depois de executadas. Este trabalho constrói e avalia o Benevente, um sistema que registra, para cada decisão, os dados admitidos, a regra quantitativa vigente, a carteira proposta, a explicação e a aprovação humana. A pesquisa segue design science e combina testes funcionais, auditoria adversarial e diagnóstico sequencial de onze decisões anuais entre 2015 e 2025. A política avaliada declara quatro perfis, do ultraconservador ao arrojado, com orçamento de renda variável, número de emissores e fração internacional congelados em registro público antes do período confirmatório, que começa em 2027. A declaração substituiu a busca de configurações depois de um experimento controlado: ampliar a seleção aninhada de 36 para 256 candidatos, com insumos idênticos, reduziu o retorno realizado em 2,63 pontos percentuais ao ano e levou o índice de Sharpe deflacionado de 0,957 a 0,777, abaixo do limiar de significância. Versão posterior trocou o caixa modelado por um instrumento comprável, e o retorno de cada perfil caiu entre 0,07 e 0,17 ponto ao ano (Seção 4.1.2). A auditoria dimensionou a dependência de proventos imputados, 13,9% da exposição acumulada a ações, e removê-los deixa o retorno em 16,55% ao ano, ainda acima do Ibovespa; recusou o selo de reconciliação externa após comparar 54 de 56 observações ativo-ano com a fonte primária, e manteve os intervalos de 95% do excesso cruzando zero contra caixa e Ibovespa. Os retornos históricos são, portanto, diagnóstico de desenvolvimento, não validação comercial. O modelo de linguagem não demonstrou ganho de retorno e permanece restrito à explicação. A contribuição não é a trilha de auditoria, e sim ligá-la a um protocolo congelado com critério de falseamento declarado.

Palavras-chave: governança de investimentos; alocação de carteira; trilha de auditoria; design science; pesquisa reprodutível.

1. INTRODUÇÃO: PROBLEMA, OBJETIVO E CONTRIBUIÇÃO

O problema é operacional: a recomendação é produzida hoje e defendida anos depois; sem preservar dado, versão da regra e aprovação, a justificativa posterior incorpora informação que não existia. O Benevente produz proposta e registro verificável no mesmo fluxo.

Quando um cliente pergunta por que uma ação entrou na carteira anos antes, o escritório precisa demonstrar três coisas.

1. Quais dados existiam naquela data: um balanço republicado em 2024 não pode aparecer como disponível em janeiro de 2023, e sem data de recebimento a justificativa incorpora informação que ninguém tinha.
2. Qual regra estava vigente naquele janeiro, com os limites de então, e não a regra de hoje.
3. Quem aprovou: decisão sem responsável não é auditável, e automação sem aprovação humana desloca a responsabilidade para um sistema que não pode respondê-la.

Uma planilha sobrescreve o próprio estado e perde a autoria das alterações; um sistema fechado entrega a carteira sem evidenciar o critério. O artefato deve permitir que um terceiro refaça a decisão sem depender da memória de quem a produziu.

A pergunta prioritária, como usar modelos de linguagem acessíveis à comunidade para apoiar decisões de investimento, torna-se no Benevente uma questão de engenharia e governança: como produzir proposta e prova no mesmo fluxo, sem transferir ao texto gerado a seleção, os pesos ou a responsabilidade.

O objetivo é construir e avaliar um artefato B2B que transforme cada recomendação em documento verificável, pelo método do design science: identificar o problema, explicitar requisitos, construir e avaliar por utilidade, qualidade e evidência (Hevner et al., 2004; Peffers et al., 2007). A avaliação combina testes, inspeção das fontes, busca deliberada de erros e diagnóstico histórico. A contribuição não é a trilha de auditoria com hash e separação de

papéis, que já é padrão, e sim ligá-la a um protocolo congelado antes do período avaliado, com critério de falseamento e início da amostra confirmatória declarados. Trilhas registram o que houve; esta se compromete de antemão com o que contaria como fracasso. O retorno passado mede o comportamento do protótipo, não sua utilidade nem o desempenho futuro.

2. PROBLEMA PRÁTICO E FUNDAMENTAÇÃO

O público inicial são escritórios de investimento, consultorias de valores mobiliários e gestão patrimonial que precisam recomendar, revisar e defender carteiras: preservar o contexto da decisão, demonstrar por que cada ativo entrou ou não, e comparar com alternativas reconhecíveis pelo cliente. O piloto comercial proposto, descrito na Seção 6.3, medirá o problema e a utilidade do artefato, sem presumir efeito sobre a economia local.

Três vieses clássicos de backtesting foram tratados como requisitos de projeto. O viés de sobrevivência é mitigado ao reconstruir o universo pelo arquivo histórico da B3 e manter os deslistados; ainda resta reconciliar integralmente seus eventos societários. O viés de antecipação, ou *look-ahead*, é mitigado pela data de recebimento de ITR e DFP e pelo corte anual; republicações e fontes auxiliares continuam sujeitas a inspeção. O viés de mineração de dados, ou *data-snooping*, é limitado pela seleção aninhada, pelo prêmio de retrospectiva e pelo Sharpe deflacionado (Bailey & López de Prado, 2014), mas onze decisões não substituem uma amostra prospectiva.

Markowitz (1952) fundamenta a comparação média-variância, ou MVO, calculada de modo independente sobre o mesmo conjunto elegível. Black e Litterman (1992) inspiram apenas a separação entre visões e alocação, não um modelo implementado. DeMiguel, Garlappi e Uppal (2009) justificam diversificação e cautela diante do erro de estimação; o MVO de 7,83% ao ano nesta execução descreve um comparador específico, não inferioridade geral. Qualidade, valor e confirmação de mercado dialogam com Novy-Marx (2013) e Fama e French (2015). Custos, giro e deslizamento entram no protocolo porque atritos podem consumir anomalias (Novy-Marx & Velikov, 2016).

A literatura recente separa utilidade narrativa de capacidade preditiva: Perlin et al. (2025), com 30 mil simulações e 1.522 empresas anonimizadas, não encontram superioridade consistente de LLM sobre 1/N ou S&P 500; Pelster e Val (2024) defendem o experimento ao vivo contra conhecimento posterior; Kim, Muhn e Nikolaev (2024) mostram extração narrativa útil sem alfa de negociação; Li et al. (2026, FINSABER) veem vantagens aparentes se deteriorarem em universos amplos e regimes distintos; FINCON (Yu et al., 2024) inspira divisão de responsabilidades, não autonomia. Esse conjunto sustenta a escolha do Benevente: a regra calcula, o modelo apenas explica fatos aprovados, e a utilidade será avaliada prospectivamente.

Essas escolhas definem o tipo de evidência que o trabalho pode produzir. O backtest é um experimento histórico sobre um protocolo, não uma simulação da experiência de cada cliente, cuja carteira implementável depende de suitability, liquidez, tributação e restrições contratuais. O artefato separa, por isso, a regra que mede o sinal, a política institucional que limita o risco e o texto explicativo que apoia a revisão humana.

3. O ARTEFATO

3.1 VISÃO GERAL

O Benevente é um sistema de apoio à decisão que executa um protocolo anual. Em janeiro, monta a carteira usando exclusivamente dados disponíveis naquela data. Mantém a carteira pelo ano, já com custos de execução. Revisa no ciclo seguinte. O resultado do ano entra depois, apenas para avaliação, e nunca retroalimenta a decisão que o gerou.

O sistema é composto por cinco camadas.

Tabela 1

Camadas do artefato e respectivas saídas auditáveis

Camada	Função	Saída auditável
Base de dados	Universo, preços e fundamentos com data	Manifesto com SHA-256 por arquivo
Elegibilidade	Tela de aprovação por ativo	Motivo de cada reprovação
Seleção e alocação	Escore multifatorial e regra quantitativa com limites	Ranking, pesos e restrições ativas
Execução	Ordens com lote e participação no volume	Custo estimado por ordem
Governança	Aprovação humana e conciliação	Quem aprovou e diferença contra a nota de corretagem

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.




Figura 1

Arquitetura e separação de responsabilidades do artefato

Nota. As setas indicam o fluxo de dados. Não existe caminho do modelo de linguagem para alterar pesos ou aprovar ordens.

O fluxo da Figura 1 separa funções que costumam aparecer misturadas: dados e fundamentos alimentam a validação; somente os ativos aceitos seguem para o cálculo; o motor quantitativo devolve pesos válidos e custos estimados; a pessoa revisa a proposta antes da aprovação. O modelo de linguagem recebe apenas fatos já calculados e os converte em nota legível, sem caminho de retorno para alterar pesos, e o dossiê registra cada etapa.

3.2 BASE DE DADOS: O UNIVERSO DE REGISTRO É A BOLSA, NÃO O PROVEDOR

O universo de registro é o arquivo histórico de cotações da própria B3, não um feed de terceiro. O painel construído cobre 514 emissores entre 2010 e 2025, dos quais 166 deixam de

negociar antes de dezembro de 2025, 77 deles antes de 2020, e 58 já haviam perdido mais de 60% do próprio topo quando pararam de negociar. Um painel montado a partir de provedor público não contém essas empresas; excluí-las equivaleria a medir apenas os sobreviventes e a superestimar o retorno da estratégia.

Preços de papéis deslistados exigem reconstruir eventos societários sem ajuda do provedor. O detector de razões redondas obteve precisão de 88,1% e recall de 23,3%; para retirá-lo da posição de fonte principal, uma rotina consultou a página pública da B3 (2026b), que respondeu para 475 das 497 séries, com 9.772 registros, 127 subscrições e 153 eventos manuais; 22 códigos ficaram sem resposta. Entre as 56 observações ativo-ano efetivamente mantidas, 54 puderam ser reconstruídas com o arquivo atual; sete divergiram do retorno ajustado publicado em mais de cinco pontos percentuais e duas observações de MRFG3 ficaram sem resposta. A série publicada continua como dado de pesquisa até que uma base histórica primária ou licenciada reproduza cada retorno desde o preço bruto.

Os fundamentos vêm dos formulários ITR e DFP da CVM, com a data de recebimento usada como porta: um documento só entra na decisão de janeiro do ano t se o regulador o recebeu antes daquela data. A ponte entre o ticker da B3 e o CNPJ da CVM é construída ano a ano e sua cobertura é publicada: em 2012, primeiro ano da série, 266 de 314 ações tiveram ponte aceita e 171, fundamentos completos.

3.3 ELEGIBILIDADE, SELEÇÃO E ALOCAÇÃO

A tela de elegibilidade reprova ativos por liquidez insuficiente, ausência de fundamento na data, alavancagem ou cobertura de juros fora do aceitável. Cada reprovação é registrada com o motivo, o que permite responder por que um papel conhecido não entrou.

O foco econômico é uma análise fundamentalista multifatorial: qualidade avalia a capacidade de remunerar o capital; valor exige preço coerente com lucros, patrimônio ou geração de caixa; o momento de doze meses funciona como confirmação de mercado; a liquidez determina se a tese é executável. Bancos e empresas operacionais recebem métricas

distintas, e o retorno histórico entra como fator complementar, sem substituir os demonstrativos.

Depois da triagem, cada ativo recebe um escore comparável dentro do universo disponível naquele janeiro. A estratégia publicada faz um corte nos melhores emissores, mantém apenas uma classe por emissor e distribui o orçamento de renda variável proporcionalmente ao escore, sujeito ao número de posições e aos limites da configuração. O saldo fica no CDI. No período aqui avaliado, a configuração completa, formada pela família de fatores, pelo número de posições e pelo orçamento de ações, era escolhida ano a ano pela seleção aninhada da Seção 4.1. Desde 25 de agosto de 2026 ela é declarada e congelada por perfil de investidor, conforme a Seção 3.4.

Essa separação também organiza os nomes. Benevente designa o produto; o módulo de seleção anual e a camada de proteção intranual, registrados como Benevente 1 e Benevente 2, são os mecanismos que a política declara por perfil (Seção 3.4); Benevente Quant AI designa a pesquisa, inclusive o experimento que combina um modelo de linguagem com um otimizador convexo. A carteira histórica publicada vem da regra multifatorial determinística. O modelo de linguagem não seleciona ativos nem define pesos: transforma fatos aprovados em tese, riscos e perguntas para revisão humana.

Sem expor o código da aplicação, a lógica é verificável: o sistema elimina ativos sem dados, liquidez ou lucro compatíveis, testa quatro leituras pré-declaradas e, na versão multifatorial, combina 40% de qualidade, 40% de lucro em relação ao preço e 20% de momento em doze meses. As 36 políticas candidatas cruzam orçamentos de ações de 55%, 75% e 95%, cestas de 5, 8 ou 12 emissores e quatro sinais; somente anos encerrados ordenam as alternativas de cada janeiro. Pesos, limites, transformações e arquivos recebem SHA-256.

3.4 A POLÍTICA VIGENTE: QUATRO PERFIS DECLARADOS

Desde agosto de 2026 o sistema opera sob uma política declarada. Em vez da busca anual, ela fixa quatro carteiras, congeladas antes da avaliação prospectiva: o ultraconservador

aloca 4% do patrimônio em renda variável entre doze emissores; o conservador, 35% entre doze; o equilibrado, 55% entre oito; o arrojado, 75% entre cinco. Em todos, um quinto do orçamento de renda variável fica no IVVB11, fundo na B3 que replica o S&P 500 em reais, definido pela política e não pelo score; o saldo fica em caixa. A camada de proteção intranual atua apenas sobre a parcela doméstica, porque o sinal de estresse é calculado sobre o Ibovespa. O registro traz os hashes dos insumos, o assinante, o critério de falseamento e o início da amostra confirmatória, e nenhum parâmetro muda sem nova versão. O ultraconservador foi declarado em 30 de agosto de 2026, quatro dias depois dos outros três, e a amostra confirmatória dos quatro começa junto, em 2027. As séries de 2026 são reconstruções de agosto, com a política aplicada retroativamente a 2 de janeiro com os dados de então; nenhuma foi acompanhada desde janeiro. As Seções 4.1.1 e 4.1.2 documentam as duas revisões; a 5.1 traz o diagnóstico.

3.5 POR QUE A DECISÃO É ANUAL

A cadência anual é coerente com o sinal e foi testada: fundamentos saem em ciclos contábeis e a tese precisa de tempo para aparecer no preço; a troca mensal vende a empresa antes do reconhecimento e multiplica decisões a justificar. A revisão em janeiro cria uma fronteira simples: o publicado até a data entra, o resto é do próximo ciclo.

Cadência anual não significa ignorar o risco por doze meses: preço, concentração, liquidez e eventos seguem monitorados, e uma política institucional pode prever gatilhos extraordinários. Significa que a reSeleção sistemática ocorre uma vez ao ano. Mantidas regra e dados, a cadência anual superou a trimestral e a mensal antes dos custos; onze anos pareados não provam otimalidade, apenas ausência de evidência para trocar a regra mais simples. Notícias não entram no retorno histórico: um radar de acompanhamento lê fontes públicas e classifica alertas para revisão humana, sem alterar ativos ou pesos, porque avaliá-las exigiria um braço prospectivo com horário de publicação e decisões arquivadas antes do desfecho.

3.6 CUSTOS, IMPOSTO E EXECUÇÃO

Duas parcelas de custo são deduzidas do retorno bruto:

- Taxas da B3 e corretagem por ordem.
- Deslizamento por participação no volume, proporcional ao tamanho da ordem em relação ao volume médio diário do papel, de modo que uma ordem grande em papel ilíquido recebe custo maior.

O imposto de renda é modelado à parte e não deduzido: toda taxa anualizada aqui é bruta de imposto. O modelo aplica 15% sobre ganho em renda variável e 17,5% sobre renda fixa de 361 a 720 dias, no ano da revisão que realiza o ganho, com liquidação integral no último ano.

O sistema recusa, por regra, ordens que ultrapassem 5% do volume médio diário do papel; a ordem não é enviada.

3.7 GOVERNANÇA: O SISTEMA PROPÕE, A PESSOA DECIDE

Quatro mecanismos delimitam o que o software pode fazer. Eles transformam a prestação de contas algorítmica em propriedade do desenho, e não em explicação produzida depois do fato (Kroll et al., 2017). A aprovação humana e o enquadramento ao perfil também são coerentes com a Resolução CVM nº 30, enquanto qualquer uso como consultoria individualizada depende da estrutura autorizada prevista na Resolução CVM nº 19 (Comissão de Valores Mobiliários, 2021a, 2021b).

1. Aprovação humana obrigatória: nenhuma ordem é transmitida, porque a arquitetura não possui esse caminho.
2. Papel delimitado do modelo de linguagem: o modelo organiza tese e riscos a partir de fatos já aprovados, sem definir peso, alterar limite ou aprovar ativo. Trata-se de restrição de arquitetura verificável, e a Seção 5.6 apresenta o experimento que testou o relaxamento dessa restrição.

3. Conciliação pós-operação: a nota de corretagem é confrontada linha a linha com a ordem proposta.
4. Limites explícitos e versionados: teto de renda variável, teto por emissor e reserva em caixa ficam na política, registrados antes da seleção.

4. MÉTODO DE AVALIAÇÃO

4.1 SEQUÊNCIA HISTÓRICA DE DESENVOLVIMENTO

O artefato admite múltiplas políticas, combinando orçamento de renda variável, número de posições e família de fatores. Publicar a melhor delas medida sobre toda a amostra seria exatamente o erro que a Seção 2 descreve. Na sequência histórica, para decidir a política do ano t , o sistema ordena as 36 candidatas usando somente os anos encerrados antes de t , pelo índice de Sharpe do excesso sobre o CDI, e adota a primeira colocada. Trocar de política é tratado como operação real e cobra rebalanceamento integral.

O ranqueamento exige no mínimo três anos encerrados. Como o painel começa em 2012, os anos de 2012 a 2014 inicializam a escolha e 2015 a 2025 formam onze decisões anuais. A ordem temporal reduz o uso direto do retorno futuro em cada decisão, mas não cria uma amostra verdadeiramente externa: os dados, filtros e hipóteses foram examinados durante o desenvolvimento do projeto. Por isso, esta janela é chamada de diagnóstico retrospectivo sequencial, e não de teste fora da amostra. O teste prospectivo começa apenas depois do congelamento descrito na Seção 4.5.

4.1.1 O experimento que motivou a política declarada

Em 25 de agosto de 2026, a defesa da Seção 4.1 foi submetida a um teste direto. Com insumos, código e janela idênticos — condição verificada pela reprodução das 36 configurações compartilhadas com diferença máxima de $5,6 \times 10^{-17}$ —, a mesma seleção aninhada sobre 256 candidatos rendeu 12,68% ao ano contra 15,31% da grade de 36, uma perda de 2,63 pontos. O Sharpe deflacionado caiu de 0,957 para 0,777, abaixo da significância, porque o máximo esperado sob a hipótese nula subiu de 0,375 para 0,746 com o

número de tentativas. Em 2018 o seletor ampliado dedicou o ano a uma configuração que rendeu $-7,2\%$ enquanto o CDI rendeu $6,4\%$. A seleção aninhada tem, portanto, um limite de capacidade: dez observações anuais não ordenam 256 candidatos, e ultrapassar o limite degrada a proteção do procedimento sem sinal visível de alerta.

A consequência de projeto foi a política declarada da Seção 3.4, congelada com assinante identificado, critério de falseamento e amostra confirmatória a partir de 2027. O experimento completo, com os controles e os negativos auxiliares, está em manuscrito próprio (`declared_over_searched_2026`), e cada número publicado é conferido por rotina automática contra os artefatos versionados. A mesma auditoria corrigiu a referência do Ibovespa, que passou a ser lida da série datada de origem — $11,74\%$ ao ano e queda de $46,8\%$ —, depois de constatada deriva na curva rebaseada do motor.

4.1.2 Resultado posterior: o caixa deixa de ser um índice (26/08/2026)

A política da Seção 4.1.1 declarava como caixa 100% do CDI capitalizado diariamente — um índice, não um instrumento: sem custódia, sem spread e sem rolagem. Registrada no dia seguinte (SHA-256 iniciado em `ca2476d4`), a versão 3 troca apenas esse componente por Tesouro Selic, reconstruído do arquivo diário do Tesouro Transparente e líquido da custódia da B3 na tabela histórica e do spread cobrado em cada rolagem. Nada mais muda, o que permite atribuir o efeito inteiro ao instrumento. O caixa rende $9,36\%$ ao ano contra $9,68\%$ do índice, e o retorno de cada perfil cai entre 0,07 e 0,17 ponto: conservador $12,34\%$, equilibrado $15,39\%$ e arrojado $19,79\%$, com quedas máximas de $-9,17\%$, $-17,88\%$ e $-28,95\%$. O excesso sobre o caixa, porém, sobe entre 0,08 e 0,18 ponto, porque o comparador é integralmente caixa e a carteira não é. A troca revelou ainda que a coluna de caixa do painel anterior é constante até 2012: a escada avalia de 2015 e não era afetada, mas a seleção aninhada ordenava com o caixa rendendo zero naquele ano, penalizando as alternativas defensivas. Como as duas pontas do experimento da Seção 4.1.1 usaram o mesmo insumo, a comparação

entre elas permanece válida; o que não se pode afirmar é que a ordenação teria sido idêntica com o caixa correto.

4.2 COMPARADORES

Três referências foram calculadas independentemente.

- CDI, série 12 do Banco Central, como custo de oportunidade do caixa.
- Ibovespa, índice de retorno total que incorpora os proventos da carteira teórica e, por isso, é comparável a uma carteira que os reinveste (B3, 2026c).
- Otimização média-variância sobre o mesmo universo elegível. Esse método estima retorno médio e covariância com dados anteriores e escolhe pesos que maximizam a relação entre retorno esperado e risco sob os mesmos limites de elegibilidade.

O último comparador merece nota: em uma versão anterior, a série rotulada como MVO era numericamente idêntica à estratégia, que assim se comparava a si mesma. O defeito foi encontrado na auditoria interna e corrigido com uma implementação independente, que passou a produzir resultados distintos, inclusive desfavoráveis à estratégia em um dos onze anos. Todos os comparadores usam as mesmas datas de início e fim da carteira.

4.3 CORREÇÃO POR MÚLTIPLAS TENTATIVAS

Com 36 configurações avaliadas, o Sharpe da vencedora precisa ser deflacionado. Calculamos o Sharpe deflacionado com o número de tentativas, o número de observações e os momentos superiores da série de retornos.

Medimos também o prêmio de retrospectiva: a diferença entre o retorno anualizado da configuração que teria vencido a amostra inteira, escolha impossível na prática, e o da escolha aninhada. Esse número quantifica o que se ganharia publicando o vencedor da busca como se fosse resultado obténível.

4.4 AUDITORIA DA QUALIDADE DOS DADOS E SENSIBILIDADE

A reconstrução de retorno total combina 497 séries; em 139 delas a distribuição de proventos precisou ser imputada por falta de cobertura do provedor. A auditoria cruzou por

ano a política, os pesos e o tipo de reconstrução, e mede a parcela da exposição a ações que dependeu de provento imputado. Três testes de sensibilidade complementam a inspeção: a reamostragem conjunta dos vetores anuais, com 100 mil amostras e semente registrada, que mede estabilidade interna sem criar crises novas; perdas hipotéticas aplicadas apenas à parcela investida em séries imputadas; e a remoção dessas séries, com o orçamento delas no caixa e a contribuição medida de cada posição.

4.5 REGISTRO PROSPECTIVO

A linhagem tem cinco registros: o módulo de seleção anual, em 16 de agosto de 2026; a camada de proteção e o protocolo de acompanhamento, após as respectivas mudanças; a política por perfil, em 25 de agosto; a revisão do caixa, em 26 de agosto, que governa esta avaliação; e o quarto degrau, em 30 de agosto, que rege decisões futuras. Extensões não herdam a data dos registros anteriores. Para sustentar uma conclusão prospectiva, cada perfil precisa superar o próprio caixa declarado e o Ibovespa após custos e tributos, respeitar o critério de falseamento do registro e acumular ao menos três decisões anuais completas posteriores ao congelamento; a amostra confirmatória começa no primeiro pregão de 2027. Nenhuma observação prospectiva havia sido consumida quando a versão 3 substituiu a 2, e por isso a contagem não recomeçou — se já tivesse sido, teria recomeçado. Não existe resultado prospectivo na data deste artigo: a carteira de janeiro de 2026 antecede os registros e é carteira-sombra.

5. RESULTADOS E DISCUSSÃO

5.1 FUNCIONAMENTO E DIAGNÓSTICO FINANCEIRO

Cada decisão anual foi emitida com fontes, hashes, elegibilidade, ranking, pesos, custos, comparadores e justificativa, e os testes de integridade recusaram arquivo alterado, peso que não soma 100%, ordem acima do limite de liquidez e fundamento recebido após a data da decisão. A auditoria da Seção 5.7 encontrou sete defeitos no próprio processo, e as correções alteraram as métricas publicadas.

A Tabela 2 traz o diagnóstico retrospectivo da política vigente sobre 2015–2025, com custos modelados e a camada aplicada à parcela doméstica. Os valores descrevem a amostra de desenvolvimento e não constituem validação prospectiva.

Tabela 2

Diagnóstico retrospectivo dos três perfis declarados entre 2015 e 2025

Perfil	Renda variável	Emissores	Retorno anualizado	Volatilidade	Queda máxima	Anos acima do CDI
Ultraconservador	4%	12	9,73%	0,74%	−0,81%	8 de 11
Conservador	35%	12	12,34%	5,85%	−9,17%	8 de 11
Equilibrado	55%	8	15,39%	10,51%	−17,88%	8 de 11
Arrojado	75%	5	19,79%	16,95%	−28,95%	8 de 11
Ibovespa	—	—	11,74%	23,37%	−46,82%	—
Tesouro Selic	—	—	9,36%	0,29%	−0,60%	—

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Os quatro perfis preservam a ordenação declarada de risco: retorno e queda máxima crescem juntos do ultraconservador ao arrojado, e nenhum se aproximou da queda máxima do Ibovespa. Só o ultraconservador fica abaixo do índice, o esperado de uma carteira com 4% em ações.

As análises das Seções 5.2 a 5.4 — imputação, reamostragem pareada e correção por múltiplas tentativas — foram conduzidas sobre a série de desenvolvimento do módulo de seleção, que tem o histórico de auditoria mais longo. A Tabela 3 traz essa série e seus comparadores, líquidos de custos estimados.

Tabela 3

Diagnóstico retrospectivo da série de desenvolvimento e dos comparadores entre 2015 e 2025

Série	Retorno anualizado	Valor final de R\$ 100 mil	Anos vencidos	Queda máxima diária
Seleção anual (Benevente 1)	17,86%	R\$ 609.832		-47,8%
Com proteção (Benevente 2), antes do IR incremental	18,45%	R\$ 643.774		-28,7%
Com proteção (Benevente 2), após estimativa do IR incremental ¹	18,29%	R\$ 634.531		-28,7%
Seleção anual (Benevente 1), após modelo anual de IR	16,03%	R\$ 513.052		
Ibovespa	11,77%	R\$ 340.068	7 de 11	-47,0%
CDI	9,61%	R\$ 274.368	6 de 11	0%
MVO neutra, mesmo universo	7,83%	R\$ 229.255	10 de 11	

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

¹ Estimativa agregada para R\$ 100 mil, com alíquota de 15%, isenção mensal quando as vendas não superam R\$ 20 mil e compensação de perdas. Ela mede apenas o imposto adicional causado pelas reduções intranuais do Benevente 2; não substitui a apuração por lote nem a conciliação de notas de corretagem.

A coluna em reais traduz a taxa anualizada em escala econômica. Esses valores dependem da qualidade da série reconstruída e devem ser lidos junto com a Seção 5.2.

Em janelas móveis, contra o CDI a série vence 8 de 9 janelas de três anos, 6 de 7 de cinco e 2 de 2 de dez; contra a otimização de referência, vence todas. As janelas se sobrepõem, então descrevem a amostra sem aumentar seu tamanho.

O retorno da série de desenvolvimento veio com risco elevado: a queda máxima diária chegou a 47,8%, próxima aos 47,0% do Ibovespa, porque entre 2018 e 2021 a política então selecionada manteve 95% em ações concentradas em cinco ou seis emissores. A camada de proteção preservou os mesmos ativos e reduziu a exposição só depois de estresse observado, levando a queda a 28,7%, com a maior perda na Covid-19. É por isso que a política vigente limita o orçamento por perfil: a amostra não permite afirmar proteção futura, mas a ordenação de risco da Tabela 2 é propriedade de construção, não de ajuste.

5.2 QUALIDADE DOS DADOS E DEPENDÊNCIA DE IMPUTAÇÃO

O painel contém 139 séries com proventos imputados, mas a carteira não as utilizou de modo uniforme. Somando somente a parcela de ações escolhida em cada ano, 13,9% da exposição acumulada dependeu de imputação. O caso mais relevante ocorreu em 2020: AZUL4 e MRFG3 representaram 50% da carteira total. Em cinco dos onze anos houve alguma exposição; nos demais, nenhuma série escolhida dependia desse procedimento.

Tabela 4

Exposição anual a séries com proventos imputados

Ano	Peso total em séries imputadas	Séries selecionadas
2015	11,0%	CIEL3
2016	24,0%	ENBR3
2020	50,0%	AZUL4 e MRFG3
2021	25,0%	MRFG3
2025	5,0%	STBP3

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Penalizar apenas a parcela imputada em 10 pontos percentuais reduz o retorno anualizado de 17,86% para 16,78%; a carteira deixa de superar o Ibovespa perto de 53 pontos de penalização, e o CDI, perto de 70. Um teste mais direto remove as séries imputadas e aplica o orçamento delas no caixa, usando a contribuição medida de cada posição: o retorno cai para 16,55%, ainda acima do Ibovespa e do CDI. A dependência se concentra em dois anos, 2021, que perde 14,7 pontos, e 2020, que passa de +1,78% para -0,51%. Como o alocador teria escolhido outro papel, e não caixa, 16,55% é piso. Nada disso repara o dado.

5.3 INCERTEZA DA AMOSTRA

A reamostragem pareada preserva, em cada sorteio, o mesmo ano da estratégia e dos comparadores. Em 100 mil amostras, a probabilidade interna de excesso positivo foi alta, mas o intervalo de 95% cruzou zero contra CDI e Ibovespa; somente a comparação com a implementação de MVO permaneceu positiva em todo o intervalo. A ordenação observada não dependeu de um único ano sorteado repetidamente, o que não equivale a superioridade na população.

Tabela 5

Incerteza do excesso de retorno em reamostragem pareada

Comparador	Amostras com excesso positivo	Mediana do excesso anualizado	Intervalo de 95%
CDI	93,4%	+8,19 p.p.	-2,27 a +20,01 p.p.
MVO de referência	100,0%	+10,06 p.p.	+4,73 a +15,29 p.p.
Ibovespa	94,4%	+5,94 p.p.	-1,31 a +14,28 p.p.

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

O limite do procedimento é importante: reamostrar onze anos não cria regimes que não estejam na série nem transforma desenvolvimento em validação externa. A informação obtida é a estabilidade interna suficiente para continuar o teste prospectivo, não a comprovação de superioridade.

5.4 CORREÇÃO POR MÚLTIPLAS TENTATIVAS

Tabela 6

Estatísticas de correção por múltiplas tentativas

Estatística	Valor
Sharpe observado do excesso sobre o CDI	0,933
Sharpe máximo esperado sob a hipótese nula, com 36 tentativas	0,355
Probabilidade do Sharpe deflacionado	0,986
Significante a 95%	sim
Prêmio de retrospectiva	0,65 p.p. ao ano

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

O prêmio de retrospectiva indica que escolher a política vencedora conhecendo toda a amostra teria rendido 0,65 ponto percentual a mais por ano do que a escolha sequencial; em uma versão anterior, com um ano a menos de histórico inicial, esse prêmio era de 4,98 pontos. O Sharpe deflacionado corrige múltiplas tentativas, mas não resolve a dependência de dados nem a ausência de teste prospectivo: é uma defesa contra uma forma específica de sobreajuste, não um certificado geral de validade.

5.5 O QUE NÃO FUNCIONOU

Oito hipóteses foram testadas e nenhuma se sustentou de forma suficiente para substituir a política principal. Elas são publicadas porque um artefato que só reporta o que deu certo não é auditável.

Ampliar a busca de configurações. Conforme a Seção 4.1.1, passar de 36 para 256 candidatos custou 2,63 pontos ao ano e a significância. Foi a rejeição que reorganizou o protocolo.

Pesar pelo inverso da volatilidade. Contra o peso publicado, proporcional ao score, o esquema perdeu em oito das oito configurações medidas, reduzindo a queda máxima em 0,95 ponto ao custo de 2,11 pontos de retorno ao ano, e piorou o pior ano justamente nas cestas largas em que deveria ajudar.

Meta de volatilidade em janeiro. O mecanismo cortou exposição em cinco de treze anos, sempre depois de um estresse visível e nunca antes de um. Em 2020, janeiro estava calmo, o ano operou com exposição integral e a queda máxima não se alterou; em 2016, a exposição foi reduzida a 8,8% de ações em um ano em que a estratégia rendeu 35%.

Previsão anual de regime. Cinco indicadores disponíveis em janeiro (prêmio de lucro sobre o CDI, nível do CDI, retorno e volatilidade de doze meses e distância do topo) tentaram antecipar se o ano favoreceria ações ou caixa. O melhor deles acertou três de quatro chamadas ($p = 0,31$), resultado indistinguível do acaso; o prêmio potencial de 6,5 pontos percentuais ao ano não foi capturado por nenhum indicador.

Realocação mensal e semanal. Em 118 períodos mensais e 521 semanais, nenhuma das sete regras contínuas superou de forma significativa o peso estático, e a regra de média-variância foi significativamente pior. O prêmio por acertar o momento existe, mas nenhum sinal testado o capturou.

Reseleção mais frequente da cesta. Questão distinta da anterior: não a proporção entre ações e caixa, mas se a própria cesta deveria ser retriada mais vezes por ano. Três cadências foram comparadas com a mesma regra, os mesmos limites e o mesmo painel; apenas as datas de decisão variam.

Tabela 7

Desempenho por cadência de reseleção da carteira

Cadência	Decisões	CAGR bruto	Líquido de custo	Após IR	Giro no ano
Anual	11	18,58%	18,51%	17,09%	62,1%
Trimestral	44	16,37%	16,25%	15,60%	116,0%
Mensal	132	13,92%	13,75%	13,32%	177,6%

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Nenhuma cadência mais rápida superou a anual: pareada por ano-calendário e após imposto, a trimestral ficou 1,55 ponto percentual abaixo ($p = 0,376$) e a mensal, 3,27 ($p = 0,306$). A leitura correta é ausência de evidência a favor, e não prova de prejuízo. A diferença nasce antes dos custos, pois o retorno bruto cai 4,66 pontos da cadência anual para a mensal, o que indica que o sinal amadurece lentamente. O modelo tributário chega a favorecer o braço mensal, que ainda assim não venceu.

Modelo de linguagem como fonte de retorno. Este é o teste que mais interessa à governança do produto, e está detalhado a seguir.

Proteção intranual concebida depois da Covid-19, com parâmetros escolhidos apenas em 2015–2018. Fora dessa janela, em 2019–2025, a diferença anual de retorno não foi detectável ($p = 0,964$): o efeito medido é de queda, não de retorno. No histórico completo a queda máxima recuou de 47,8% para 28,7% e o retorno anualizado subiu de 17,86% para 18,45%, e a Tabela 2 mantém as duas séries separadas. Para R\$ 100 mil, o imposto incremental das reduções foi de R\$ 2.195, levando o valor terminal de R\$ 643.774 para R\$ 634.531. A camada integra a política declarada da Seção 3.4.

5.6 O EXPERIMENTO COM MODELO DE LINGUAGEM: TRÊS RESULTADOS NULOS

O produto restringe o modelo de linguagem à explicação. Um experimento retrospectivo separado permitiu que ele produzisse escore ou pesos apenas para medir o custo dessa restrição. Como o treinamento do modelo pode conter notícias e desfechos posteriores, os quatro braços são diagnóstico de sensibilidade, não validação temporal da LLM.

Uma extensão prospectiva medirá fidelidade, completude, cobertura de riscos e números inventados da camada de linguagem. Ela não seleciona ativos nem herda resultados anteriores.

- Nomeado: o modelo vê os nomes das empresas e devolve um escore limitado, que inclina o retorno esperado dentro do otimizador convexo.
- Anonimizado: idêntico, mas com as empresas identificadas por números, de modo que o modelo vê fundamentos e não marcas.
- Determinístico: controle sem modelo, ordenando o mesmo universo pelo escore de fator pré-declarado.
- Monolítico: o contrafactual em que o modelo devolve pesos diretamente, sem otimizador nem restrições.

Tabela 8

Comparações do experimento com modelo de linguagem

Comparação	Diferença anualizada	p
Nomeado menos anonimizado (contaminação temporal)	+0,38 p.p.	0,905
Anonimizado menos determinístico (valor agregado pelo modelo)	-0,05 p.p.	0,989
Anonimizado menos monolítico (valor do desacoplamento)	+0,81 p.p.	0,777

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Os três resultados não permitem rejeitar a hipótese de ausência de diferença, e cada um responde a uma pergunta distinta.

1. Não houve diferença detectável entre identificar as empresas pelo nome e ocultar sua identidade, o que não prova ausência de contaminação: o modelo pode inferir a empresa pelos fundamentos ou reconhecer padrões aprendidos depois do período.
2. O modelo não agregou retorno: o braço anonimizado ficou 0,05 ponto percentual abaixo do controle determinístico, com $p = 0,989$.
3. Manter o modelo longe dos pesos não penalizou o resultado. Quando recebeu essa função, ele produziu vetores que não somavam 100% em cinco dos treze anos e omitiu dezenas de ativos elegíveis sem sinalizar.

A conclusão de produto: o modelo organiza e explica decisões, mas não as gera. Qualquer uso futuro em sinal, ranking ou peso terá de começar depois do registro específico da versão avaliada e ser comparado prospectivamente ao controle determinístico.

5.7 DEFEITOS ENCONTRADOS NA PRÓPRIA AUDITORIA

A auditoria interna adversarial encontrou e corrigiu sete defeitos, todos na direção de inflar o resultado.

Tabela 9

Defeitos identificados na auditoria interna e respectivas correções

Defeito	Efeito	Correção
Comparador MVO idêntico à estratégia	Comparação da estratégia consigo mesma	Implementação independente
Painel de provedor descartava deslistadas	Viés de sobrevivência	Universo reconstruído do arquivo da B3
Ano de deslistagem descartado inteiro	Perda truncava o ano	Liquidação da posição em CDI
Imposto ausente	Retorno superestimado	Modelo tributário brasileiro
Custo fixo ignorando liquidez	Ordem grande sem penalidade	Deslizamento por participação no volume
Rebalanceamento diário implícito	Artefato de vetorização	Trajectoria de compra e manutenção
Filtro de sessões usando pico global	Anos legítimos descartados	Pico móvel local

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Depois da última correção, o retorno anualizado publicado caiu e a queda máxima subiu de 30,4% para 47,8%. A mudança evidencia o funcionamento do controle, que foi capaz de piorar o resultado quando os dados o exigiram, mas não prova que todos os defeitos foram encontrados.

6. APLICABILIDADE, IMPLANTAÇÃO E MODELO DE USO

6.1 PÚBLICO E PROPOSTA DE VALOR

O produto foi concebido para escritórios de investimento, consultorias e gestores patrimoniais. A política aplicada, os dados e seus hashes, a elegibilidade, os pesos, as ordens, o custo estimado e a aprovação permanecem ligados à mesma decisão, o que reduz o tempo de reconstrução e permite responder por que um papel entrou e por que outro ficou de fora. O

valor a testar está na consistência do processo e na revisão, não em promessa de superar o mercado.

6.2 FLUXO OPERACIONAL

O uso começa pelo perfil declarado adequado ao cliente. O usuário vê quais arquivos estavam disponíveis e quais passaram na validação; a triagem mostra aprovados e reprovados com o motivo; a carteira candidata apresenta pesos, parcela defensiva, custo e comparação com CDI, Ibovespa e MVO. O profissional revisa a tese, registra riscos, aprova ou rejeita e justifica; o dossiê reúne esse percurso com a versão da regra.

6.3 IMPLANTAÇÃO E PILOTO COMERCIAL

A implantação começa por fontes, políticas, acessos e aprovadores. No piloto o sistema acompanha poucas carteiras sem enviar ordens, e os dossiês são confrontados com o processo vigente; a conciliação de custos e posições fecha o ciclo. O piloto medirá tempo, completude da evidência, revisões, divergência de custos e disposição a pagar; é lá que a intensidade do problema se mede. O produto permanece em protótipo, com hashes versionados e data carimbada por terceiro.

6.4 MATRIZ DE EVIDÊNCIAS

A Tabela 10 delimita o que pode ser afirmado na submissão.

Tabela 10

Matriz de afirmações, evidências e situação

Afirmação	Evidência disponível	Situação
O artefato preserva dados, regra, pesos e aprovação	Testes funcionais, hashes e dossiês reproduzíveis	Demonstrada no protótipo
A auditoria encontra erros que alteram métricas	Sete defeitos reproduzidos e corrigidos	Demonstrada no desenvolvimento
A regra superou comparadores entre 2015 e 2025	Diagnóstico sequencial e reamostragem interna	Observada, não prospectiva
A série histórica tem qualidade institucional	13,9% da exposição a ações dependeu de imputação	Não demonstrada
O modelo de linguagem gera retorno adicional	Diferença de -0,05 p.p. e $p = 0,989$	Não demonstrada
Há demanda e disposição a pagar	Piloto ainda não executado	Não demonstrada
A regra funciona em dados futuros	Registros congelados de 2026; amostra confirmatória a partir de 2027	Em acompanhamento

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

A matriz converge com a literatura: ausência de alfa do modelo (Perlin et al., 2025; Li et al., 2026), valor narrativo sem autorização de pesos (Kim et al., 2024) e exigência prospectiva (Pelster & Val, 2024).

7. LIMITAÇÕES E RECOMENDAÇÕES

7.1 LIMITAÇÕES

A primeira limitação é temporal: onze decisões anuais são poucas, e a janela também serviu ao desenvolvimento. O prêmio de retrospectiva e o Sharpe deflacionado tratam parte do risco de múltiplas tentativas, mas não equivalem a validação prospectiva.

A segunda limitação está nos dados. A página atual da B3 respondeu para 95,6% das séries consultadas, percentual que mede resposta do serviço, não completude histórica; a reconstrução das posições mantidas encontrou sete diferenças materiais em 54 comparações e duas observações sem resposta. Papéis sem cobertura completa recebem distribuição imputada pela mediana transversal do ano; a Seção 5.2 mede o alcance e o efeito disso. O arquivo novo melhora a auditabilidade porque permite reprovar a própria reconciliação; não transforma a curva em evidência institucional.

A terceira é econômica. Na série de desenvolvimento a queda máxima chegou a 47,8%, pior que os 47,0% do Ibovespa; a camada reduziu essa marca para 28,7%, mas foi concebida depois da Covid-19 (Seção 5.5); o imposto de renda variável é apurado por ativo e custo médio, e resta conciliar com notas de corretagem. A política limita a exposição por perfil, com quedas máximas retrospectivas entre 9,2% e 28,9%, mas seus parâmetros também foram definidos com conhecimento da amostra.

Por fim, o produto não elimina responsabilidade profissional: uso comercial exige enquadramento regulatório, suitability, segurança, contrato de fontes e aprovação humana. O modelo de linguagem não seleciona ativos nem define pesos, e o radar de notícias serve apenas ao alerta humano, sem participar do retorno histórico.

7.2 RECOMENDAÇÕES DE PESQUISA E IMPLANTAÇÃO

O passo científico prioritário é acumular decisões posteriores aos registros congelados. Em paralelo, uma versão institucional precisará de um livro histórico de eventos capaz de cobrir os 22 códigos não devolvidos e de reproduzir as sete diferenças materiais encontradas no escopo da estratégia. Testes seguintes devem acrescentar trajetórias sintéticas com regimes de baixa prolongada, sem substituir a observação futura; um estudo com notícias deve ser registrado como braço separado, com horário verificável. O passo de produto é um piloto silencioso, sem execução automática, que meça tempo, completude documental, divergência de custos, compreensão do usuário e disposição a pagar.

8. CONCLUSÃO

O Benevente foi construído para resolver uma falha operacional específica: carteiras são propostas em um momento e justificadas em outro, enquanto os dados, a regra e a aprovação podem se separar. O protótipo mostrou que é possível produzir a alocação e a evidência da decisão no mesmo fluxo, com fundamentos admitidos pela data de recebimento, regra quantitativa separada da explicação em linguagem natural, custos, imposto e comparadores independentes.

No diagnóstico 2015–2025, os quatro perfis superaram o CDI em oito de onze anos cada um, com quedas escalonadas conforme o perfil; a incerteza amostral e a imputação parcial impedem tratar isso como superioridade comprovada. Os negativos são parte da contribuição: reselecionar mais vezes não ajudou, o modelo de linguagem não acrescentou retorno, a alocação direta por texto saiu aritmeticamente inconsistente em parte dos anos e a própria busca se degradou ao ser ampliada. O conjunto justifica um sistema em que a regra calcula, a linguagem explica e uma pessoa responde.

A conclusão sustentada pela evidência é estreita. O artefato cria uma cadeia auditável e a usa para achar erros que alteram o próprio resultado — inclusive recusando um selo que os dados não sustentavam e trocando um caixa que não era comprável — e para medir o

limite do próprio procedimento de seleção. A viabilidade comercial depende de um piloto que meça ganho de tempo, completude documental, compreensão e disposição a pagar. A validade financeira exigirá uma base histórica reconciliável e observações posteriores aos registros congelados; a amostra confirmatória da política vigente começa no primeiro pregão de 2027. Até lá, o desempenho histórico permanece diagnóstico de desenvolvimento.

9. DISPONIBILIDADE

Código, testes, manifestos e arquivos de evidência estão em <https://github.com/diegogallina1/benevente>, com fontes, limitações e comandos de reprodução documentados. A demonstração está em <https://benevente-wealth-system.vercel.app/>.

REFERÊNCIAS

- Bailey, D. H., Borwein, J. M., López de Prado, M., & Zhu, Q. J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
<https://doi.org/10.21314/JCF.2016.322>
- Bailey, D. H., & López de Prado, M. (2014). The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality. *Journal of Portfolio Management*, 40(5), 94–107. <https://doi.org/10.3905/jpm.2014.40.5.094>
- Banco Central do Brasil. (2026). *Sistema Gerenciador de Séries Temporais: série 12, taxa de juros CDI*. <https://www3.bcb.gov.br/sgspub/>
- B3 S.A. – Brasil, Bolsa, Balcão. (2026a). *Cotações históricas: série histórica de preços dos títulos negociados na Bolsa*.
https://www.b3.com.br/pt_br/market-data-e-indices/servicos-de-dados/market-data/historico/mercado-a-vista/cotacoes-historicas/
- B3 S.A. – Brasil, Bolsa, Balcão. (2026b). *Dividendos e outros eventos corporativos*.
<https://sistemaswebb3-listados.b3.com.br/dividendsOtherCorpActPage/>

- B3 S.A. – Brasil, Bolsa, Balcão. (2026c). *Ibovespa B3*. https://www.b3.com.br/pt_br/market-data-e-indices/indices/indices-amplos/ibovespa.htm
- Benevente. (2026). *Documentação técnica, repositório de dados e validação de horizontes*. <https://github.com/diegogallina1/benevente>
- Black, F., & Litterman, R. (1992). Global portfolio optimization. *Financial Analysts Journal*, 48(5), 28–43. <https://doi.org/10.2469/faj.v48.n5.28>
- Comissão de Valores Mobiliários. (2021a). *Resolução CVM nº 19, de 25 de fevereiro de 2021: atividade de consultoria de valores mobiliários* (texto consolidado). <https://conteudo.cvm.gov.br/legislacao/resolucoes/resol019.html>
- Comissão de Valores Mobiliários. (2021b). *Resolução CVM nº 30, de 11 de maio de 2021: adequação dos produtos, serviços e operações ao perfil do cliente* (texto consolidado). <https://conteudo.cvm.gov.br/legislacao/resolucoes/resol030.html>
- Comissão de Valores Mobiliários. (2026a). *Demonstrações Financeiras Padronizadas (DFP): dados abertos*. https://dados.cvm.gov.br/dataset/cia_aberta-doc-dfp
- Comissão de Valores Mobiliários. (2026b). *Formulário de Informações Trimestrais (ITR): dados abertos*. https://dados.cvm.gov.br/dados/CIA_ABERTA/DOC/ITR/DADOS/
- DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *Review of Financial Studies*, 22(5), 1915–1953. <https://doi.org/10.1093/rfs/hhm075>
- Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22. <https://doi.org/10.1016/j.jfineco.2014.10.010>
- Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75–105. <https://doi.org/10.2307/25148625>
- Kim, A. G. H., Muhn, M., & Nikolaev, V. V. (2024). *Financial statement analysis with large language models* [Working paper]. arXiv. <https://arxiv.org/abs/2407.17866>

- Kroll, J. A., Huey, J., Barocas, S., Felten, E. W., Reidenberg, J. R., Robinson, D. G., & Yu, H. (2017). Accountable algorithms. *University of Pennsylvania Law Review*, 165(3), 633–705.
- Li, Y., Kim, K., Cucuringu, M., & Ma, S. (2026). Can LLM-based financial investing strategies outperform the market in long run? In *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining* (pp. 2711–2722).
<https://doi.org/10.1145/3770854.3785702>
- López de Prado, M. (2018). *Advances in financial machine learning*. Wiley.
- Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
<https://doi.org/10.2307/2975974>
- Novy-Marx, R. (2013). The other side of value: The gross profitability premium. *Journal of Financial Economics*, 108(1), 1–28. <https://doi.org/10.1016/j.jfineco.2013.01.003>
- Novy-Marx, R., & Velikov, M. (2016). A taxonomy of anomalies and their trading costs. *Review of Financial Studies*, 29(1), 104–147. <https://doi.org/10.1093/rfs/hhv063>
- Peffer, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45–77. <https://doi.org/10.2753/MIS0742-1222240302>
- Pelster, M., & Val, J. (2024). Can ChatGPT assist in picking stocks? *Finance Research Letters*, 59, 104786. <https://doi.org/10.1016/j.frl.2023.104786>
- Perlin, M. S., Foguesatto, C. R., Müller, F. M., & Righi, M. B. (2025). Can AI beat a naive portfolio? An experiment with anonymized data. *Finance Research Letters*, 107126.
<https://doi.org/10.1016/j.frl.2025.107126>
- Yu, Y., Yao, H., Jiang, H., Lu, Y., Cao, Y., Yan, D., & Zhuang, F. (2024). FinCon: A synthesized LLM multi-agent system with conceptual verbal reinforcement for enhanced financial decision making. In *Advances in Neural Information Processing Systems 37*.
<https://doi.org/10.52202/079017-4354>