

BENEVENTE WEALTH SYSTEM: UM ARTEFATO AUDITÁVEL PARA DECISÕES DE CARTEIRA

Diego Gallina

Fucape Business School, Vitória, ES, Brasil

Resumo

Decisões de carteira precisam continuar explicáveis depois de executadas. Este trabalho constrói e avalia o Benevente Wealth System, um artefato de apoio à decisão que reúne, no mesmo registro, os dados admitidos, a regra quantitativa, a carteira proposta, a explicação e a aprovação humana. A pesquisa segue design science e avalia o artefato por testes funcionais, auditoria adversarial e um diagnóstico histórico sequencial de onze decisões entre 2015 e 2025. A auditoria encontrou sete defeitos capazes de inflar resultados e revelou uma limitação material: 13,9% da exposição acumulada a ações selecionadas dependeu de séries com proventos imputados. Por isso, o retorno histórico é apresentado como diagnóstico de desenvolvimento, não como validação comercial. Uma reamostragem pareada indica estabilidade interna, mas os intervalos de 95% do excesso de retorno cruzam zero contra CDI, Ibovespa e BOVA11. O protocolo prospectivo foi congelado em 16 de agosto de 2026 e ainda não possui observações suficientes para conclusão. O modelo de linguagem não demonstrou ganho de retorno e permanece restrito à explicação. A contribuição comprovada é a separação verificável entre dado, cálculo, linguagem e responsabilidade.

Palavras-chave: governança de investimentos; alocação de carteira; trilha de auditoria; design science; pesquisa reprodutível.

1. INTRODUÇÃO: PROBLEMA, OBJETIVO E CONTRIBUIÇÃO

Este trabalho parte de um problema operacional: a recomendação é produzida hoje, mas pode precisar ser defendida anos depois. Sem preservar o dado admitido, a versão da regra e a aprovação, a justificativa posterior pode incorporar informações inexistentes na decisão. O Benevente produz a proposta e seu registro verificável. A intensidade do problema e a disposição a pagar ainda precisam ser medidas em piloto. O artigo não atribui ao artefato impacto regional ou demanda comercial não observados.

O problema é concreto e tem data. Quando um cliente pergunta em 2026 por que determinada ação entrou na carteira em janeiro de 2023, o escritório precisa demonstrar três coisas simultaneamente.

1. Quais dados existiam naquela data. Um balanço republicado em 2024 não pode aparecer como se estivesse disponível em janeiro de 2023. Sem controle de data de recebimento, todo backtest e toda justificativa ficam contaminados por informação que ninguém tinha.
2. Qual regra foi aplicada. Não a regra que o escritório usa hoje, mas a que estava vigente naquele janeiro, com os limites que estavam vigentes.
3. Quem aprovou. Uma decisão de alocação sem responsável identificado não é auditável, e a automação sem aprovação humana desloca a responsabilidade para um sistema que não pode respondê-la.

Planilhas sem controle de versão podem sobrescrever estados, misturar regra e dado e perder autoria. Sistemas fechados podem entregar uma carteira sem evidenciar o critério. O artefato deve permitir que uma pessoa independente refaça a decisão sem depender da memória de quem a produziu.

A pergunta prioritária é: como usar modelos de linguagem acessíveis à comunidade para apoiar decisões de investimento, e quão úteis são essas ferramentas para a tomada de decisão? No Benevente, ela se torna uma questão de engenharia e governança: como produzir

proposta e prova no mesmo fluxo, sem transferir ao texto gerado a seleção, os pesos ou a responsabilidade?

O objetivo é construir e avaliar um artefato B2B que transforme cada recomendação em documento verificável. O método segue design science: identificar o problema, explicitar requisitos, construir e avaliar o artefato por utilidade, qualidade e evidência (Hevner et al., 2004; Peffers et al., 2007). A avaliação combina testes, inspeção das fontes, busca deliberada de erros e diagnóstico financeiro histórico. A contribuição reúne um protocolo quantitativo reexecutável e um fluxo que preserva quem decidiu, com qual informação e política. O retorno passado mede o comportamento do protótipo, não sua utilidade principal nem o desempenho futuro.

2. PROBLEMA PRÁTICO E FUNDAMENTAÇÃO

O público inicial do Benevente são escritórios de investimento, consultorias de valores mobiliários e estruturas de gestão patrimonial que precisam recomendar, revisar e defender carteiras. Nesse ambiente, a dificuldade não termina quando o peso de cada ativo é calculado. A instituição precisa preservar o contexto da decisão, demonstrar por que um ativo foi aceito ou recusado e comparar o resultado com alternativas reconhecíveis pelo cliente. O piloto comercial proposto poderá ser realizado no Espírito Santo por conveniência e aderência ao congresso, mas sua função será medir o problema e a utilidade do artefato, não confirmar antecipadamente um efeito sobre a economia local.

Três vieses clássicos de backtesting foram tratados como requisitos de projeto. O viés de sobrevivência é mitigado ao reconstruir o universo pelo arquivo histórico da B3 e manter os deslistados; ainda resta reconciliar integralmente seus eventos societários. O viés de antecipação, ou *look-ahead*, é mitigado pela data de recebimento de ITR e DFP e pelo corte anual; republicações e fontes auxiliares continuam sujeitas a inspeção. O viés de mineração de dados, ou *data-snooping*, é limitado pela seleção aninhada, pelo prêmio de retrospectiva e

pelo Sharpe deflacionado (Bailey & López de Prado, 2014), mas onze decisões não substituem uma amostra prospectiva.

Markowitz (1952) fundamenta a comparação média-variância, ou MVO, calculada de modo independente sobre o mesmo conjunto elegível. Black e Litterman (1992) inspiram apenas a separação entre visões e alocação, não um modelo implementado. DeMiguel, Garlappi e Uppal (2009) justificam diversificação e cautela diante do erro de estimação; o MVO de 7,83% ao ano nesta execução descreve um comparador específico, não inferioridade geral. Qualidade, valor e confirmação de mercado dialogam com Novy-Marx (2013) e Fama e French (2015). Custos, giro e deslizamento entram no protocolo porque atritos podem consumir anomalias (Novy-Marx & Velikov, 2016).

Os estudos recentes também recomendam separar utilidade narrativa de capacidade preditiva. Perlin et al. (2025) executaram 30 mil simulações com 1.522 empresas anonimizadas e não encontraram superioridade consistente do Gemini sobre 1/N ou S&P 500, sobretudo em horizontes longos. Pelster e Val (2024) adotaram um experimento ao vivo, desenho mais adequado para evitar conhecimento posterior. Kim, Muhn e Nikolaev (2024) reportam que modelos podem extrair informações narrativas úteis de demonstrativos anonimizados, sem que isso implique alfa de negociação. Li et al. (2026), no FINSABER, mostram que vantagens aparentes se deterioram em universos amplos, horizontes longos e regimes distintos. FINCON (Yu et al., 2024) inspira a divisão de responsabilidades, não autonomia de negociação. Esse conjunto sustenta a escolha do Benevente: a regra determinística calcula, o modelo apenas explica fatos aprovados e sua utilidade será avaliada prospectivamente.

Essas escolhas definem o tipo de evidência que o trabalho pode produzir. O backtest é um experimento histórico sobre um protocolo e não uma simulação da experiência individual de todo cliente. Suitability, necessidade de liquidez, tributação específica, ativos já detidos e restrições contratuais podem mudar a carteira implementável. Por isso, o artefato separa três

objetos que costumam aparecer misturados: a regra acadêmica usada para medir o sinal; a política institucional que limita o risco; e o texto explicativo que ajuda uma pessoa a revisar a decisão. Uma boa curva não substitui nenhum dos três.

O posicionamento do artefato decorre desses três pontos. O Benevente não é apresentado como gerador comprovado de alfa. Seu diferencial verificável é manter unidos os insumos, a regra, a explicação e a aprovação. O diagnóstico histórico serve para pressionar essa arquitetura e revelar erros, inclusive quando a correção piora o resultado publicado.

3. O ARTEFATO

3.1 VISÃO GERAL

O Benevente Wealth System é um sistema de apoio à decisão que executa um protocolo anual. Em janeiro, monta a carteira usando exclusivamente dados disponíveis naquela data. Mantém a carteira pelo ano, já com custos de execução. Revisa no ciclo seguinte. O resultado do ano entra depois, apenas para avaliação, e nunca retroalimenta a decisão que o gerou.

O sistema é composto por cinco camadas.

Tabela 1

Camadas do artefato e respectivas saídas auditáveis

Camada	Função	Saída auditável
Base de dados	Universo, preços e fundamentos com data	Manifesto com SHA-256 por arquivo
Elegibilidade	Tela de aprovação por ativo	Motivo de cada reprovação
Seleção e alocação	Score multifatorial e regra quantitativa com limites	Ranking, pesos e restrições ativas
Execução	Ordens com lote e participação no volume	Custo estimado por ordem
Governança	Aprovação humana e conciliação	Quem aprovou e diferença contra a nota de corretagem

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.




Figura 1

Arquitetura e separação de responsabilidades do artefato

Nota. As setas indicam o fluxo de dados. Não existe caminho do modelo de linguagem para alterar pesos ou aprovar ordens.

O fluxo da Figura 1 separa funções que costumam aparecer misturadas. Dados e fundamentos alimentam a validação. Somente os ativos aceitos seguem para o cálculo. O motor quantitativo devolve pesos válidos e custos estimados. A pessoa revisa a proposta antes da aprovação. O modelo de linguagem recebe apenas fatos já calculados e os converte em uma nota legível, sem caminho de retorno para alterar pesos. O dossiê registra cada uma dessas etapas.

3.2 BASE DE DADOS: O UNIVERSO DE REGISTRO É A BOLSA, NÃO O PROVEDOR

O universo de registro é o arquivo histórico de cotações da própria B3, não um feed de terceiro. A consequência é direta e mensurável. O painel construído cobre 514 emissores entre 2010 e 2025, dos quais 166 deixam de negociar antes de dezembro de 2025, 77 deles antes de 2020, e 58 já haviam perdido mais de 60% do próprio topo quando pararam de negociar. Um painel montado a partir de provedor público simplesmente não contém essas empresas. A diferença entre incluí-las e não incluí-las é a diferença entre medir a estratégia e medir a sorte de ter olhado só para os sobreviventes.

Preços deslistados exigem tratamento de eventos societários sem a ajuda do provedor. A primeira versão detectava razões de preço redondas e obteve precisão de 88,1%, mas recall de apenas 23,3% contra o arquivo de eventos disponível. Para retirar essa heurística da posição de fonte principal, uma nova rotina consultou diretamente os registros públicos da B3 e arquivou 18.190 dividendos, juros sobre capital próprio, desdobramentos, grupamentos, bonificações e eventos manuais. A consulta cobriu 475 de 497 ativos do painel. Vinte e dois códigos não foram devolvidos pela página atual e 271 eventos, entre eles 218 subscrições, ainda exigem resolução de direitos e conversões. A série publicada não foi requalificada: ela continua como dado de pesquisa até ser reconstruída desde o preço bruto, com cobertura integral e cada evento aplicado em relatório próprio.

Os fundamentos vêm dos formulários ITR e DFP da CVM, com a data de recebimento usada como porta: um documento só entra na decisão de janeiro do ano t se o regulador o recebeu antes daquela data. A ponte entre o ticker da B3 e o CNPJ da CVM é construída ano a ano, e sua cobertura é publicada em vez de suposta. Em 2012, primeiro ano da série, 266 de 314 ações tiveram ponte aceita e 171 tiveram fundamentos completos, porque a série do ITR começa em 2011 e 2012 é o primeiro ano em que a construção de doze meses tem os dois lados disponíveis.

3.3 ELEGIBILIDADE, SELEÇÃO E ALOCAÇÃO

A tela de elegibilidade reprova ativos por liquidez insuficiente, ausência de fundamento na data, alavancagem ou cobertura de juros fora do aceitável. Cada reprovação é registrada com o motivo, o que permite ao escritório responder por que um papel conhecido não entrou, pergunta que aparece com a mesma frequência da inversa.

O foco econômico é uma análise fundamentalista multifatorial. Qualidade procura empresas capazes de remunerar o capital e sustentar a operação; valor procura um preço coerente com lucros, patrimônio ou geração de caixa; momento de doze meses funciona como confirmação de mercado e reduz a compra mecânica de uma empresa barata que continua

deteriorando. Liquidez determina se a tese é executável. Bancos e empresas operacionais recebem métricas diferentes porque dívida e margem operacional não significam a mesma coisa nos dois balanços. O retorno histórico entra como fator complementar, não substitui os demonstrativos.

Depois da triagem, cada ativo recebe um escore comparável dentro do universo disponível naquele janeiro. A estratégia publicada faz um corte nos melhores emissores, mantém apenas uma classe por emissor e distribui o orçamento de renda variável proporcionalmente ao escore, sujeito ao número de posições e aos limites da configuração. O saldo fica no CDI. A configuração completa — família de fatores, número de posições e orçamento de ações — é escolhida anualmente pelo desempenho ajustado ao risco nos anos já encerrados. A otimização média-variância não define essa carteira. Ela é calculada de modo independente, sobre o mesmo universo elegível, para medir o que uma carteira puramente quantitativa de média e covariância teria produzido.

Essa separação também resolve a ambiguidade entre os nomes. Benevente Quant AI designa a pesquisa acadêmica, inclusive o experimento que combina um modelo de linguagem com um otimizador convexo. Benevente Wealth System designa o produto B2B de governança que entrega proposta, explicação e registro. A carteira histórica publicada é a regra multifatorial determinística. O modelo de linguagem não seleciona ativo e não escreve peso; seu papel é transformar fatos aprovados em tese, riscos e perguntas para revisão humana.

Sem expor o código da aplicação, a lógica é verificável. O sistema elimina ativos sem dados, liquidez ou lucro compatíveis, testa quatro leituras pré-declaradas e, na versão multifatorial, combina 40% de qualidade, 40% de lucro em relação ao preço e 20% de momento em doze meses. As 36 políticas candidatas cruzam orçamentos de ações de 55%, 75% e 95%, cestas de 5, 8 ou 12 emissores e quatro sinais. Somente anos encerrados podem

ordenar as alternativas de cada janeiro. Pesos, limites, transformações e arquivos recebem SHA-256.

3.4 POR QUE A DECISÃO É ANUAL

A cadência anual é uma hipótese coerente com a natureza do sinal e, neste estudo, uma escolha empiricamente testada. Qualidade, retorno sobre capital, alavancagem e geração de caixa são grandezas divulgadas em ciclos contábeis e cuja tese econômica precisa de tempo para aparecer no preço. Uma troca mensal baseada nelas pode vender uma empresa antes que a melhora operacional seja reconhecida e aumenta o número de decisões que precisam ser justificadas. A revisão em janeiro também cria uma fronteira operacional simples: tudo o que foi publicado até a data pode entrar; tudo o que veio depois pertence ao próximo ciclo.

Anual não significa que o sistema ignora o risco durante doze meses. Preços, concentração, liquidez e eventos materiais podem ser monitorados continuamente, e uma política institucional pode prever um gatilho extraordinário. Significa apenas que a reseleção sistemática da cesta acontece uma vez por ano. No teste de robustez, mantendo regra e dados constantes, a reseleção anual superou as versões trimestral e mensal antes mesmo dos custos. Com apenas onze anos pareados, isso não prova que a frequência anual seja universalmente ótima; mostra que não houve evidência para substituir a regra mais simples nesta amostra.

Notícias não entram no modelo atual. Esse limite é intencional: um estudo com notícias exige arquivo histórico licenciado, horário de publicação, deduplicação e uma data de corte verificável para o modelo de linguagem. Misturar notícias retrospectivamente ao protocolo anual criaria uma nova oportunidade de usar informação futura. O estudo futuro adequado é um braço separado, pré-registrado, com revisão trimestral ou por evento e notícias carimbadas no tempo, comparado à regra anual sem alterar esta última.

3.5 CUSTOS, IMPOSTO E EXECUÇÃO

Retorno bruto não é resultado. O sistema modela três parcelas.

- Taxas da B3 e corretagem por ordem.

- Deslizamento por participação no volume, proporcional ao tamanho da ordem relativo ao volume médio diário do papel. Uma ordem grande em papel ilíquido custa mais, como custa na prática.
- Imposto de renda brasileiro, com 15% sobre ganho realizado em renda variável e 17,5% sobre renda fixa na faixa de 361 a 720 dias, cobrado no ano em que a revisão seguinte efetivamente realiza o ganho, e com liquidação integral assumida no último ano avaliado. Essa é a hipótese terminal conservadora, em vez de um diferimento indefinido que embelezaria a série.

O sistema recusa, por regra, ordens que ultrapassem 5% do volume médio diário do papel. A ordem falha em vez de ser enviada.

3.6 GOVERNANÇA: O SISTEMA PROPÕE, A PESSOA DECIDE

Quatro mecanismos delimitam o que o software pode fazer. Eles transformam a prestação de contas algorítmica em propriedade do desenho, e não em explicação produzida depois do fato (Kroll et al., 2017). A aprovação humana e o enquadramento ao perfil também são coerentes com a Resolução CVM nº 30, enquanto qualquer uso como consultoria individualizada depende da estrutura autorizada prevista na Resolução CVM nº 19 (Comissão de Valores Mobiliários, 2021a, 2021b).

1. Aprovação humana obrigatória. Nenhuma ordem é transmitida, nem pode ser, porque a arquitetura não tem esse caminho.
2. Papel delimitado do modelo de linguagem. O modelo organiza tese e riscos a partir de fatos já aprovados. Ele não define peso, não altera limite e não aprova ativo. Isso é uma restrição de arquitetura verificável, não uma promessa de conduta, e a Seção 5.5 mostra o experimento que testou o que aconteceria se ela fosse relaxada.
3. Conciliação pós-operação. A nota de corretagem é confrontada linha a linha com a ordem proposta.

4. Limites explícitos e versionados. Teto de renda variável, teto por emissor e reserva em caixa ficam na política, registrados antes da seleção.

4. MÉTODO DE AVALIAÇÃO

4.1 SEQUÊNCIA HISTÓRICA DE DESENVOLVIMENTO

O artefato admite múltiplas políticas, combinando orçamento de renda variável, número de posições e família de fatores. Publicar a melhor delas medida sobre toda a amostra seria exatamente o erro que a Seção 2 descreve. Na sequência histórica, para decidir a política do ano t , o sistema ordena as 36 candidatas usando somente os anos encerrados antes de t , pelo índice de Sharpe do excesso sobre o CDI, e adota a primeira colocada. Trocar de política é tratado como operação real e cobra rebalanceamento integral.

O ranqueamento exige no mínimo três anos encerrados. Como o painel começa em 2012, os anos de 2012 a 2014 inicializam a escolha e 2015 a 2025 formam onze decisões anuais. A ordem temporal reduz o uso direto do retorno futuro em cada decisão, mas não cria uma amostra verdadeiramente externa: os dados, filtros e hipóteses foram examinados durante o desenvolvimento do projeto. Por isso, esta janela é chamada de diagnóstico retrospectivo sequencial, e não de teste fora da amostra. O teste prospectivo começa apenas depois do congelamento descrito na Seção 4.5.

4.2 COMPARADORES

Quatro referências foram calculadas de forma independente.

- CDI, série 12 do Banco Central, como custo de oportunidade do caixa.
- Ibovespa, índice de retorno total que incorpora os proventos da carteira teórica e, por isso, é comparável a uma carteira que os reinveste (B3, 2026b).
- BOVA11, ETF negociável que busca acompanhar o Ibovespa e permite observar uma implementação passiva sujeita a taxa, custos de negociação e diferença de aderência (BlackRock, 2026).

- Otimização média-variância sobre o mesmo universo elegível. Esse método estima retorno médio e covariância com dados anteriores e escolhe pesos que maximizam a relação entre retorno esperado e risco sob os mesmos limites de elegibilidade.

Esse último merece nota. Em uma versão anterior do sistema, a série rotulada como MVO de referência era numericamente idêntica à estratégia em todos os anos, ou seja, a estratégia estava sendo comparada a si mesma. O defeito foi encontrado na auditoria interna, corrigido com uma implementação independente, e o comparador passou a produzir resultados distintos, inclusive desfavoráveis à estratégia em um dos onze anos.

Ibovespa e BOVA11 não são duplicatas. O primeiro mede o retorno total de uma carteira teórica e estabelece a referência econômica do mercado. O segundo representa um caminho efetivamente negociável para buscar essa exposição. A pequena diferença entre as duas séries é informativa, pois reúne taxa, fricções operacionais e erro de aderência. Todos os comparadores usam as mesmas datas de início e fim da carteira.

4.3 CORREÇÃO POR MÚLTIPLAS TENTATIVAS

Com 36 configurações avaliadas, o Sharpe da vencedora precisa ser deflacionado. Calculamos o Sharpe deflacionado com o número de tentativas, o número de observações e os momentos superiores da série de retornos.

Medimos também o prêmio de retrospectiva, que é a diferença entre o CAGR da configuração que teria vencido a amostra inteira, escolha impossível na prática porque usa os anos sobre os quais é medida, e o CAGR da escolha aninhada. Esse número quantifica exatamente o que um concorrente ganharia publicando o vencedor da busca como se fosse resultado obténível.

4.4 AUDITORIA DA QUALIDADE DOS DADOS E SENSIBILIDADE

A reconstrução de retorno total combina 497 séries. Em 139 delas, a distribuição de proventos precisou ser imputada porque não havia cobertura integral do provedor. Uma contagem por ticker seria insuficiente, pois uma série problemática pode nunca entrar na

carteira. A auditoria cruzou, por ano, a política realmente escolhida, os pesos dos ativos e o tipo de reconstrução de cada série. A medida principal é a parcela da exposição acumulada a ações que dependeu de provento imputado.

Dois testes de sensibilidade complementam essa inspeção. O primeiro reamostra, em conjunto, os vetores anuais completos de retorno da estratégia e de cada comparador. Foram produzidas 100 mil amostras com semente registrada. O pareamento conserva a relação observada em cada ano e mede estabilidade interna, mas não cria crises novas nem corrige a fonte. O segundo aplica perdas hipotéticas de 10, 25, 50 e 100 pontos percentuais somente à parcela anual investida em séries imputadas. O objetivo é mostrar quanto o resultado depende dessa hipótese, e não adivinhar qual teria sido o provento correto.

4.5 REGISTRO PROSPECTIVO

O protocolo prospectivo foi congelado em 16 de agosto de 2026, com hash e data registrados no repositório. A política precisa superar, após imposto, o CDI e o ETF investível de mercado, manter queda máxima inferior a 35% e acumular pelo menos três anos antes de uma conclusão. Não existe resultado prospectivo suficiente na data deste artigo. Essa ausência é um resultado de estágio do projeto, não uma lacuna a preencher com o histórico. A regra registrada não poderá ser alterada depois de observado um ano desfavorável sem que a mudança constitua um novo protocolo e uma nova contagem.

5. RESULTADOS E DISCUSSÃO

5.1 FUNCIONAMENTO E DIAGNÓSTICO FINANCEIRO

O artefato produziu, para cada decisão anual, um registro com fontes, hashes, elegibilidade, ranking, pesos, custos estimados, comparadores e justificativa. Os testes de integridade recusaram arquivos alterados, pesos que não somavam 100%, ordens acima do limite de liquidez e fundamentos recebidos depois da decisão. A auditoria adversarial descrita na Seção 5.7 encontrou sete defeitos no próprio processo de pesquisa. Corrigi-los mudou as

métricas, o que demonstra que o registro é capaz de contestar o resultado que o sistema produz.

A Tabela 2 apresenta o diagnóstico financeiro de onze decisões, de 2015 a 2025, líquido de custos estimados. Ele descreve o comportamento do protótipo durante o desenvolvimento. Não é validação prospectiva nem demonstração de que a carteira repetirá o desempenho.

Tabela 2

Diagnóstico retrospectivo da carteira e dos comparadores entre 2015 e 2025

Série	Retorno anualizado	Valor final de R\$ 100 mil	Anos vencidos	Queda máxima diária
Benevente 1	17,86%	R\$ 609.832		-47,8%
Benevente, após IR	16,03%	R\$ 513.052		
Ibovespa	11,77%	R\$ 340.068	7 de 11	-47,0%
BOVA11 (ETF investível)	11,72%	R\$ 338.545	7 de 11	-47,2%
CDI	9,61%	R\$ 274.368	6 de 11	0%
MVO neutra, mesmo universo	7,83%	R\$ 229.255	10 de 11	

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

A coluna em reais traduz a taxa anualizada em escala econômica. Sob as hipóteses do diagnóstico, R\$ 100 mil teriam terminado em R\$ 609.832 na carteira, R\$ 340.068 no Ibovespa e R\$ 274.368 no CDI. Esses valores dependem da qualidade da série reconstruída e devem ser lidos junto com a Seção 5.2.

Em janelas móveis, contra o CDI a carteira vence 8 de 9 janelas de três anos, 6 de 7 de cinco anos e 2 de 2 de dez anos. Contra a otimização de referência, vence todas as janelas de três, cinco e dez anos. Essas contagens não são observações independentes: as nove janelas de três anos contêm apenas três blocos sem sobreposição, e as de dez anos contêm apenas um. Elas descrevem a amostra, mas não aumentam artificialmente seu tamanho.

O retorno veio acompanhado de risco elevado. A queda máxima diária chegou a 47,8%, praticamente igual à do Ibovespa, 47,0%, e à do BOVA11, 47,2%. Entre 2018 e 2021, a política selecionada manteve 95% em ações e concentrou essa parcela em cinco ou seis

emissores. O sistema não antecipou a Covid-19 e não protegeu o capital durante a queda. A carteira sofreu quase todo o recuo do mercado e recuperou-se depois. Portanto, o resultado é incompatível com a promessa de perfil conservador e não pode ser vendido como proteção de crise.

5.2 QUALIDADE DOS DADOS E DEPENDÊNCIA DE IMPUTAÇÃO

O painel contém 139 séries com proventos imputados, mas a carteira não as utilizou de modo uniforme. Somando somente a parcela de ações escolhida em cada ano, 13,9% da exposição acumulada dependeu de imputação. O caso mais relevante ocorreu em 2020: AZUL4 e MRFG3 representaram 50% da carteira total. Em cinco dos onze anos houve alguma exposição; nos demais, nenhuma série escolhida dependia desse procedimento.

Tabela 3

Exposição anual a séries com proventos imputados

Ano	Peso total em séries imputadas	Séries selecionadas
2015	11,0%	CIEL3
2016	24,0%	ENBR3
2020	50,0%	AZUL4 e MRFG3
2021	25,0%	MRFG3
2025	5,0%	STBP3

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Aplicar uma perda adicional de 10 pontos percentuais apenas à parcela imputada reduz o retorno anualizado da carteira de 17,86% para 16,78%. Com 25 pontos, ele cai para 15,11%; com 50, para 12,16%; e com 100, para 5,41%. A carteira deixa de superar o Ibovespa quando a penalização nessa parcela chega a aproximadamente 53 pontos percentuais e deixa de superar o CDI perto de 70 pontos. O teste mostra alguma margem econômica, mas não repara o dado. Como metade da carteira de 2020 dependeu de séries imputadas, o retorno histórico deve permanecer diagnóstico até a reconciliação dos eventos e proventos em fonte primária.

5.3 INCERTEZA DA AMOSTRA

A reamostragem pareada preserva, em cada sorteio, o mesmo ano da estratégia e dos comparadores. Em 100 mil amostras, a probabilidade interna de excesso positivo foi alta, mas

o intervalo de 95% ainda cruzou zero contra CDI, Ibovespa e BOVA11. Somente a comparação com a implementação específica de MVO permaneceu positiva em todo o intervalo. Isso não autoriza concluir que o Benevente supera esses referenciais na população; mostra apenas que a ordenação observada não dependeu de um único ano sorteado repetidamente.

Tabela 4

Incerteza do excesso de retorno em reamostragem pareada

Comparador	Amostras com excesso positivo	Mediana do excesso anualizado	Intervalo de 95%
CDI	93,4%	+8,19 p.p.	-2,27 a +20,01 p.p.
MVO de referência	100,0%	+10,06 p.p.	+4,73 a +15,29 p.p.
Ibovespa	94,4%	+5,94 p.p.	-1,31 a +14,28 p.p.
BOVA11	94,3%	+5,98 p.p.	-1,34 a +14,41 p.p.

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

O limite do procedimento é importante. Reamostrar onze anos não cria um mercado de baixa prolongado que não esteja na série, não produz novas trajetórias de inflação e juros e não transforma desenvolvimento em validação externa. A informação correta é que há estabilidade interna suficiente para continuar o teste prospectivo, não que a superioridade esteja comprovada.

5.4 CORREÇÃO POR MÚLTIPLAS TENTATIVAS

Tabela 5

Estatísticas de correção por múltiplas tentativas

Estatística	Valor
Sharpe observado do excesso sobre o CDI	0,933
Sharpe máximo esperado sob a hipótese nula, com 36 tentativas	0,355
Probabilidade do Sharpe deflacionado	0,986
Significante a 95%	sim
Prêmio de retrospectiva	0,65 p.p. ao ano

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

O prêmio de retrospectiva diz que escolher a política vencedora conhecendo toda a amostra teria rendido 0,65 ponto percentual a mais por ano do que a escolha sequencial. Em uma versão anterior, com um ano a menos de histórico inicial, esse prêmio era de 4,98 pontos.

Ampliar a base reduziu a parcela do retorno explicada pela escolha posterior da regra. O Sharpe deflacionado também corrige múltiplas tentativas, mas não resolve a dependência de dados nem a ausência de teste prospectivo. Ele é uma defesa contra uma forma específica de sobreajuste, não um certificado geral de validade.

5.5 O QUE NÃO FUNCIONOU

Cinco hipóteses foram testadas e nenhuma se sustentou de forma suficiente para substituir a política principal. Elas são publicadas porque um artefato que só reporta o que deu certo não é auditável.

Previsão anual de regime. Testamos se indicadores disponíveis em janeiro, entre prêmio de lucro sobre o CDI, nível do CDI, retorno e volatilidade do mercado nos doze meses anteriores e distância do topo, anteciparam se o ano seria de ações ou de caixa. Sobre 8 anos, o melhor preditor acertou 3 de 4 chamadas efetivas, com p de 0,31 contra cara-ou-coroa. Um acerto de 75% em quatro tentativas não distingue habilidade de sorte. O prêmio disponível para quem acertasse todas as chamadas era de 6,5 pontos percentuais ao ano, e permanece inalcançável. Sem sinal.

Realocação mensal e semanal. Em 118 períodos mensais e 521 semanais, nenhuma das sete regras contínuas superou de forma significativa o peso estático. A regra de média-variância foi significativamente pior. O prêmio por acertar o tempo existe, mas nenhum sinal testado o capturou.

Reseleção mais frequente da cesta. A objeção seguinte é diferente da anterior e precisa ser separada dela: não se a proporção entre ações e caixa deve mudar mais vezes, que é o que o parágrafo acima rejeita, mas se a própria cesta deveria ser retriada, reordenada e reotimizada mais vezes por ano. Testamos três cadências com a mesma regra, os mesmos limites e o mesmo painel, variando apenas as datas de decisão.

Tabela 6

Desempenho por cadência de reseleção da carteira

Cadência	Decisões	CAGR bruto	Líquido de custo	Após IR	Giro no ano
Anual	11	18,58%	18,51%	17,09%	62,1%
Trimestral	44	16,37%	16,25%	15,60%	116,0%
Mensal	132	13,92%	13,75%	13,32%	177,6%

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Nenhuma cadência mais rápida superou a anual. Pareando por ano-calendário, a trimestral fica 1,55 ponto percentual abaixo ao ano após imposto, com p de 0,376, e a mensal 3,27 pontos abaixo, com p de 0,306. A leitura correta é que não há evidência de que decidir mais vezes ajude, e não que esteja provado que atrapalhe: onze anos pareados não sustentam a afirmação mais forte.

A diferença surgiu antes dos custos: o retorno bruto caiu 4,66 pontos da cadência anual para a mensal. O sinal combina qualidade, valor e momento, grandezas de maturação lenta. O modelo tributário subestima o imposto do braço mensal ao não acompanhar o lote vendido; esse viés favorece a alternativa que mesmo assim não venceu.

Modelo de linguagem como fonte de retorno. Este é o teste que mais interessa à governança do produto, e está detalhado a seguir.

Proteção intranual concebida depois da Covid-19. O Benevente 2 reduz a exposição após estresse de queda e volatilidade do Ibovespa. No histórico, a queda máxima recuou de 47,8% para 28,7%, sem diferença detectável de retorno entre 2019 e 2025 ($p = 0,964$). Por perfil, a proteção reduziu a queda de 18,9% para 9,9% no conservador, de 28,1% para 17,9% no equilibrado e de 37,6% para 29,3% no arrojado, com pequena redução do CAGR. Em 5.000 reamostragens de blocos, o percentil adverso de 2,5% chegou a 14,2%, 27,7% e 49,1%. A regra foi registrada em 20 de agosto de 2026 para acompanhamento em 2027. Ela permanece retrospectiva, sem imposto intranual, e não integra o resultado principal.

5.6 O EXPERIMENTO COM MODELO DE LINGUAGEM: TRÊS RESULTADOS NULOS

O produto restringe o modelo de linguagem à explicação. Um experimento retrospectivo separado permitiu que ele produzisse escore ou pesos apenas para medir o custo dessa restrição. Como o treinamento do modelo pode conter notícias e desfechos posteriores, os quatro braços são diagnóstico de sensibilidade, não validação temporal da LLM.

- Nomeado: o modelo vê os nomes das empresas e devolve um escore limitado, que inclina o retorno esperado dentro do otimizador convexo.
- Anonimizado: idêntico, mas as empresas são identificadas apenas por números, de modo que o modelo vê os fundamentos e não as marcas.
- Determinístico: controle sem modelo algum, ordenando o mesmo universo pelo escore de fator pré-declarado.
- Monolítico: o contrafactual em que o modelo devolve pesos diretamente, sem otimizador e sem restrições.

Tabela 7

Comparações do experimento com modelo de linguagem

Comparação	Diferença anualizada	p
Nomeado menos anonimizado (contaminação temporal)	+0,38 p.p.	0,905
Anonimizado menos determinístico (valor agregado pelo modelo)	-0,05 p.p.	0,989
Anonimizado menos monolítico (valor do desacoplamento)	+0,81 p.p.	0,777

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Os três resultados estatísticos não permitem rejeitar a hipótese de ausência de diferença, e cada um responde a uma pergunta diferente.

1. Não houve diferença detectável entre identificar as empresas pelo nome e ocultar sua identidade. Isso não prova ausência de contaminação: o modelo pode inferir a empresa pelos fundamentos ou reconhecer padrões aprendidos depois do período avaliado.
2. O modelo não agregou retorno. O braço anonimizado ficou 0,05 ponto percentual abaixo do controle determinístico, com $p = 0,989$.

3. Manter o modelo longe dos pesos não penalizou o resultado. Quando recebeu essa função, ele produziu vetores que não somavam 100% em 5 dos 13 anos e omitiu dezenas de ativos elegíveis sem sinalizar. O otimizador garante uma alocação válida antes da explicação.

A conclusão de produto é direta. O modelo organiza e explica decisões, mas não as gera. Qualquer futuro uso em sinal, ranking ou peso terá de começar depois do protocolo congelado em 16 de agosto de 2026 e ser comparado prospectivamente ao controle determinístico.

5.7 DEFEITOS ENCONTRADOS NA PRÓPRIA AUDITORIA

O artefato passou por auditoria interna adversarial. Sete defeitos foram encontrados e corrigidos, e todos inflavam o resultado.

Tabela 8

Defeitos identificados na auditoria interna e respectivas correções

Defeito	Efeito	Correção
Comparador MVO idêntico à estratégia	Comparação da estratégia consigo mesma	Implementação independente
Painel de provedor descartava deslistadas	Viés de sobrevivência	Universo reconstruído do arquivo da B3
Ano de deslistagem descartado inteiro	Perda truncava o ano	Liquidação da posição em CDI
Imposto ausente	Retorno superestimado	Modelo tributário brasileiro
Custo fixo ignorando liquidez	Ordem grande sem penalidade	Deslizamento por participação no volume
Rebalanceamento diário implícito	Artefato de vetorização	Trajetória de compra e manutenção
Filtro de sessões usando pico global	Anos legítimos descartados	Pico móvel local

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Depois da última correção, o retorno anualizado publicado caiu e a queda máxima subiu de 30,4% para 47,8%. Essa mudança é uma evidência de funcionamento do processo de controle: a auditoria foi capaz de piorar a narrativa quando os dados assim exigiram. Ela não prova que todos os defeitos foram encontrados.

6. APLICABILIDADE, IMPLANTAÇÃO E MODELO DE USO

6.1 PÚBLICO E PROPOSTA DE VALOR

O produto foi concebido para escritórios de investimento, consultorias de valores mobiliários, gestores patrimoniais e escritórios multifamiliares. Para a instituição, o Benevente transforma a documentação em consequência do próprio trabalho: a política aplicada, os dados e seus hashes, a elegibilidade, os pesos, as ordens, o custo estimado e a aprovação permanecem ligados à mesma decisão. Para o profissional, isso reduz o tempo gasto reconstruindo uma recomendação. Para o cliente, permite responder tanto por que um papel entrou quanto por que outro ficou de fora.

O benefício comercial não deve ser apresentado como promessa de superar o mercado. O valor a testar está na consistência do processo, na comparação explícita com alternativas e na capacidade de revisão. O retorno continua sendo medido, acompanhado e discutido, sem se tornar garantia ou substituto da adequação ao perfil do cliente.

6.2 FLUXO OPERACIONAL

O uso começa pela política da instituição. Depois de escolher o perfil e aceitar seus limites, o usuário vê quais arquivos e demonstrações estavam disponíveis e quais passaram na validação. A triagem mostra aprovados e reprovados com o respectivo motivo. A carteira candidata apresenta pesos, parcela defensiva, custo e comparação com CDI, Ibovespa, BOVA11 e MVO. Em seguida, o profissional revisa a tese em linguagem natural, registra riscos, aprova ou rejeita a proposta e informa a justificativa. O dossiê final reúne esse percurso e a versão da regra. Laboratório e documento de decisão são, portanto, duas vistas do mesmo registro, e não etapas desconectadas.

6.3 IMPLANTAÇÃO E PILOTO COMERCIAL

A implantação começa pela definição de fontes, políticas, acessos e aprovadores. No piloto, o sistema acompanha poucas carteiras sem enviar ordens e os dossiês são confrontados com o processo vigente. Na operação assistida, a conciliação de custos e posições fecha o

ciclo entre proposta e execução. Integrações com corretora, custódia, identidade e arquivo pertencem a essa etapa e não bloqueiam o teste inicial.

A oferta a validar combina licença institucional e implantação. O piloto medirá tempo, completude da evidência, revisões, diferença entre custo estimado e executado e disposição a pagar. Um teste no Espírito Santo atende ao recorte do congresso, mas não permite presumir retenção de capital ou negócios no estado. Esse efeito exigiria pesquisa própria.

O produto permanece em estágio de protótipo reproduzível. A janela de 2015 a 2025 foi usada no desenvolvimento e descreve a amostra, não o futuro. A avaliação prospectiva começa no registro congelado, cujo hash foi versionado e recebeu data carimbada por terceiro. Essa separação entre diagnóstico e acompanhamento futuro é parte do produto, não apenas uma ressalva acadêmica.

6.4 MATRIZ DE EVIDÊNCIAS

A Tabela 9 delimita o que pode ser afirmado na data da submissão. Ela também serve como contrato de comunicação para a demonstração do produto.

Tabela 9

Matriz de afirmações, evidências e situação

Afirmação	Evidência disponível	Situação
O artefato preserva dados, regra, pesos e aprovação	Testes funcionais, hashes e dossiês reproduzíveis	Demonstrada no protótipo
A auditoria encontra erros que alteram métricas	Sete defeitos reproduzidos e corrigidos	Demonstrada no desenvolvimento
A regra superou comparadores entre 2015 e 2025	Diagnóstico sequencial e reamostragem interna	Observada, não prospectiva
A série histórica tem qualidade institucional	13,9% da exposição a ações dependeu de imputação	Não demonstrada
O modelo de linguagem gera retorno adicional	Diferença de -0,05 p.p. e $p = 0,989$	Não demonstrada
Há demanda e disposição a pagar	Piloto ainda não executado	Não demonstrada
A regra funciona em dados futuros	Registro de 16/08/2026, mínimo de três anos	Em acompanhamento

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

A matriz converge com a literatura externa. A ausência de alfa atribuído ao modelo é compatível com Perlin et al. (2025) e com o desgaste de vantagens em testes longos descrito

por Li et al. (2026). O valor narrativo ainda plausível acompanha Kim et al. (2024), mas não autoriza pesos. A linha prospectiva adota a exigência empírica ilustrada por Pelster e Val (2024). Assim, cada achado externo reforça uma fronteira do artefato: cálculo determinístico, explicação limitada e responsabilidade humana.

7. LIMITAÇÕES E RECOMENDAÇÕES

7.1 LIMITAÇÕES

A primeira limitação é temporal. Onze decisões anuais são poucas, e a janela avaliada também serviu ao desenvolvimento. O prêmio de retrospectiva de 0,65 ponto percentual e o Sharpe deflacionado tratam parte do risco de múltiplas tentativas, mas não equivalem a validação prospectiva. A reamostragem também não cria regimes que a história não contém.

A segunda limitação está nos dados. A coleta primária avançou para 18.190 eventos e 95,6% dos ativos do painel, mas 22 códigos e 271 eventos manuais ainda bloqueiam a reconciliação integral. Papéis sem cobertura completa recebem, em casos identificados, uma distribuição imputada pela mediana transversal do ano. Essa fragilidade atingiu 13,9% da exposição acumulada a ações e 50% da carteira total em 2020. O novo arquivo melhora a auditabilidade, mas o resultado só poderá ser recalculado e comparado quando o preço bruto, o evento e a conversão estiverem ligados sem lacunas.

A terceira é econômica. A queda máxima diária chegou a 47,8%, nível incompatível com um perfil conservador e ligeiramente pior que os 47,0% do Ibovespa. O protótipo não demonstrou proteção de capital. A extensão de controle de risco concebida depois da Covid-19 é retrospectiva, não tem imposto intranual conciliado e não demonstrou retorno adicional.

Por fim, o produto não elimina responsabilidade profissional. Uso comercial exige enquadramento regulatório, política de suitability, segurança, contrato de fontes e aprovação humana. O modelo de linguagem não antecipou a Covid-19, não seleciona ativos e não define

pesos. Notícias também não entram no protocolo atual porque não há, neste experimento, um arquivo histórico com horário de publicação e corte verificável.

7.2 RECOMENDAÇÕES DE PESQUISA E IMPLANTAÇÃO

O passo científico prioritário é acumular decisões depois do registro congelado. Em paralelo, a pesquisa deve completar os 22 códigos e resolver os 271 eventos manuais antes de reconstruir o retorno. A reamostragem em blocos já mede dependência serial curta; testes seguintes devem acrescentar trajetórias sintéticas com regimes de baixa prolongada que não estejam limitadas à ordem histórica. Simulação não substitui observação futura. Um estudo com notícias deve ser registrado como braço separado, com frequência trimestral ou orientada a eventos e horário verificável. O passo de produto é um piloto silencioso, sem execução automática, capaz de medir tempo, completude documental, divergência de custos, compreensão do usuário e disposição a pagar.

8. CONCLUSÃO

O Benevente Wealth System foi construído para resolver uma falha operacional específica: carteiras são propostas em um momento e justificadas em outro, enquanto os dados, a regra e a aprovação podem se separar. O protótipo mostrou que é possível produzir a alocação e a evidência da decisão no mesmo fluxo, com fundamentos admitidos pela data de recebimento, regra quantitativa separada da explicação em linguagem natural, custos, imposto e comparadores independentes.

No diagnóstico de 2015 a 2025, a carteira apresentou retorno anualizado superior aos comparadores e queda máxima semelhante à do mercado. A incerteza da amostra e a dependência parcial de séries imputadas impedem tratar essa diferença como superioridade comprovada. Os testes negativos são informativos: a frequência anual não perdeu para reseleções mais rápidas, o modelo de linguagem não acrescentou retorno e a alocação direta por texto produziu carteiras aritmeticamente inconsistentes em parte dos anos. Esses achados

justificam um sistema em que a matemática calcula a alocação, a linguagem ajuda a compreendê-la e uma pessoa conserva a responsabilidade final.

A conclusão comprovada é mais estreita e mais defensável que a versão anterior do artigo: o artefato cria uma cadeia auditável e usa essa cadeia para descobrir erros que mudam o próprio resultado. A viabilidade comercial será confirmada somente se um piloto mostrar ganho de tempo, completude documental, compreensão e disposição a pagar. A validade financeira exigirá completar a reconciliação primária e acumular dados posteriores ao registro; a política de risco começa sua amostra confirmatória em 2027. Até lá, o desempenho histórico permanece diagnóstico de desenvolvimento.

9. DISPONIBILIDADE

O código de reprodução, os testes, os manifestos criptográficos e os arquivos que sustentam os resultados estão disponíveis no repositório público do projeto, em <https://github.com/diegogallina1/benevente>. A demonstração web do artefato está disponível em <https://benevente-wealth-system.vercel.app/>. O repositório identifica as fontes, as limitações de cobertura e os comandos necessários para reproduzir as avaliações.

REFERÊNCIAS

- Bailey, D. H., Borwein, J. M., López de Prado, M., & Zhu, Q. J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
<https://doi.org/10.21314/JCF.2016.322>
- Bailey, D. H., & López de Prado, M. (2014). The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality. *Journal of Portfolio Management*, 40(5), 94–107. <https://doi.org/10.3905/jpm.2014.40.5.094>
- Banco Central do Brasil. (2026). *Sistema Gerenciador de Séries Temporais: série 12, taxa de juros CDI*. <https://www3.bcb.gov.br/sgspub/>
- B3 S.A. – Brasil, Bolsa, Balcão. (2026a). *Cotações históricas: série histórica de preços dos títulos negociados na Bolsa*.

- https://www.b3.com.br/pt_br/market-data-e-indices/servicos-de-dados/market-data/historico/mercado-a-vista/cotacoes-historicas/
- B3 S.A. – Brasil, Bolsa, Balcão. (2026b). *Ibovespa B3*. https://www.b3.com.br/pt_br/market-data-e-indices/indices/indices-amplos/ibovespa.htm
- Benevente Wealth System. (2026). *Documentação técnica, repositório de dados e validação de horizontes*. <https://github.com/diegogallina1/benevente>
- Black, F., & Litterman, R. (1992). Global portfolio optimization. *Financial Analysts Journal*, 48(5), 28–43. <https://doi.org/10.2469/faj.v48.n5.28>
- BlackRock. (2026). *iShares Ibovespa Fundo de Índice (BOVA11): factsheet*. <https://www.blackrock.com/br/literature/fact-sheet/bova11-ishares-ibovespa-fundo-de-ndice-fund-fact-sheet-pt-lm.pdf>
- Comissão de Valores Mobiliários. (2021a). *Resolução CVM nº 19, de 25 de fevereiro de 2021: atividade de consultoria de valores mobiliários* (texto consolidado). <https://conteudo.cvm.gov.br/legislacao/resolucoes/resol019.html>
- Comissão de Valores Mobiliários. (2021b). *Resolução CVM nº 30, de 11 de maio de 2021: adequação dos produtos, serviços e operações ao perfil do cliente* (texto consolidado). <https://conteudo.cvm.gov.br/legislacao/resolucoes/resol030.html>
- Comissão de Valores Mobiliários. (2026a). *Demonstrações Financeiras Padronizadas (DFP): dados abertos*. https://dados.cvm.gov.br/dataset/cia_aberta-doc-dfp
- Comissão de Valores Mobiliários. (2026b). *Formulário de Informações Trimestrais (ITR): dados abertos*. https://dados.cvm.gov.br/dados/CIA_ABERTA/DOC/ITR/DADOS/
- DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *Review of Financial Studies*, 22(5), 1915–1953. <https://doi.org/10.1093/rfs/hhm075>
- Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22. <https://doi.org/10.1016/j.jfineco.2014.10.010>

- Harvey, C. R., Liu, Y., & Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68. <https://doi.org/10.1093/rfs/hhv059>
- Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75–105. <https://doi.org/10.2307/25148625>
- Kim, A. G. H., Muhn, M., & Nikolaev, V. V. (2024). *Financial statement analysis with large language models* [Working paper]. arXiv. <https://arxiv.org/abs/2407.17866>
- Kroll, J. A., Huey, J., Barocas, S., Felten, E. W., Reidenberg, J. R., Robinson, D. G., & Yu, H. (2017). Accountable algorithms. *University of Pennsylvania Law Review*, 165(3), 633–705.
- Li, Y., Kim, K., Cucuringu, M., & Ma, S. (2026). Can LLM-based financial investing strategies outperform the market in long run? In *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining* (pp. 2711–2722). <https://doi.org/10.1145/3770854.3785702>
- López de Prado, M. (2018). *Advances in financial machine learning*. Wiley.
- Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91. <https://doi.org/10.2307/2975974>
- Novy-Marx, R. (2013). The other side of value: The gross profitability premium. *Journal of Financial Economics*, 108(1), 1–28. <https://doi.org/10.1016/j.jfineco.2013.01.003>
- Novy-Marx, R., & Velikov, M. (2016). A taxonomy of anomalies and their trading costs. *Review of Financial Studies*, 29(1), 104–147. <https://doi.org/10.1093/rfs/hhv063>
- Peppers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45–77. <https://doi.org/10.2753/MIS0742-1222240302>
- Pelster, M., & Val, J. (2024). Can ChatGPT assist in picking stocks? *Finance Research Letters*, 59, 104786. <https://doi.org/10.1016/j.frl.2023.104786>

- Perlin, M. S., Foguesatto, C. R., Müller, F. M., & Righi, M. B. (2025). Can AI beat a naive portfolio? An experiment with anonymized data. *Finance Research Letters*, 107126. <https://doi.org/10.1016/j.frl.2025.107126>
- Yu, Y., Yao, H., Jiang, H., Lu, Y., Cao, Y., Yan, D., & Zhuang, F. (2024). FinCon: A synthesized LLM multi-agent system with conceptual verbal reinforcement for enhanced financial decision making. In *Advances in Neural Information Processing Systems* 37. <https://doi.org/10.52202/079017-4354>