

Benevente Wealth System: um artefato de decisão e governança de carteira para escritórios de investimento do Espírito Santo

Artigo tecnológico submetido ao 6º Business Tech Congress, 2026.

Resumo

Escritórios de investimento capixabas, entre multi-family offices, consultorias de valores mobiliários e assessorias, recomendam carteiras que precisam ser justificadas meses depois de montadas, diante do cliente, da área de conformidade ou do regulador. Três perguntas voltam sempre: quais dados existiam na data da decisão, qual regra foi aplicada sobre eles e quem aprovou. Planilha não responde nenhuma. Plataforma de terceiro costuma responder à segunda de forma opaca. Este trabalho tem como objetivo construir e avaliar o Benevente Wealth System, um artefato de software que produz a proposta de carteira e sua trilha de auditoria no mesmo ato. A avaliação combina design science, seleção anual aninhada e teste histórico sequencial. Cada decisão sai acompanhada da política vigente, dos fundamentos recebidos pela CVM até a data de corte, da elegibilidade com o motivo de cada reprovação, dos pesos, das ordens propostas com lote e participação no volume, do custo estimado e do SHA-256 dos arquivos que geraram os números. O artefato foi avaliado em onze decisões anuais, de 2015 a 2025, sobre um painel da B3 reconstruído do arquivo histórico de cotações e que conserva 166 emissores que deixam de negociar antes do fim da amostra. A carteira publicada, denominada Benevente 1, rendeu 17,86% ao ano após custos, ou 16,03% após imposto de renda, contra 11,77% do Ibovespa, 9,61% do CDI e 7,83% de uma otimização média-variância independente sobre o mesmo universo elegível. Venceu o mercado em sete dos onze anos e a otimização neutra em dez. Uma extensão experimental, Benevente 2, preserva a seleção anual e reduz temporariamente a exposição quando queda e volatilidade observadas no fechamento anterior ultrapassam limiares registrados. Na amostra completa ela reduziu a queda máxima de 47,8% para 28,7%, mas no recorte temporal de 2019 a 2025 não demonstrou retorno adicional ($p = 0,964$). Reportamos também o que não funcionou: previsão anual de regime, realocação mensal e semanal da proporção entre ações e caixa, reseleção mais frequente da própria cesta e o uso de um modelo de linguagem como fonte de retorno. A contribuição tecnológica não é uma promessa de rentabilidade. É um sistema verificável que separa dado, regra, alocação, explicação e aprovação, inclusive quando uma melhoria protege o capital sem comprovar alfa.

Palavras-chave: governança de investimentos; trilha de auditoria; alocação de carteira; informação disponível na data; viés de sobrevivência; pesquisa reprodutível.

1. Introdução: problema, objetivo e contribuição

Este trabalho parte de uma hipótese de mercado a ser validada no piloto: escritórios do Espírito Santo que mantêm o relacionamento com famílias e empresas locais podem depender de infraestrutura de decisão produzida fora do estado. O problema proposto não é falta de competência analítica. É a ausência de uma ferramenta que produza, no ato da recomendação, o registro que a recomendação vai exigir depois. A pesquisa ainda não mede o tamanho desse mercado, a disposição a pagar ou a taxa de adoção. Portanto, retenção de capital e geração de negócios no estado são resultados esperados do produto, não resultados já comprovados.

O problema é concreto e tem data. Quando um cliente pergunta em 2026 por que determinada ação entrou na carteira em janeiro de 2023, o escritório precisa demonstrar três coisas simultaneamente.

1. Quais dados existiam naquela data. Um balanço republicado em 2024 não pode aparecer como se estivesse disponível em janeiro de 2023. Sem controle de data de recebimento, todo backtest e toda justificativa ficam contaminados por informação que ninguém tinha.
2. Qual regra foi aplicada. Não a regra que o escritório usa hoje, mas a que estava vigente naquele janeiro, com os limites que estavam vigentes.
3. Quem aprovou. Uma decisão de alocação sem responsável identificado não é auditável, e a automação sem aprovação humana desloca a responsabilidade para um sistema que não pode respondê-la.

Planilhas falham nas três: sobrescrevem o estado anterior, misturam regra e dado, e não guardam autoria. Plataformas de terceiros costumam responder à segunda pergunta com uma caixa fechada, entregando ao escritório a carteira e não o critério. Nenhuma das duas alternativas serve a quem responde pela decisão.

A questão que orienta este trabalho é, portanto, de engenharia e de governança antes de ser de finanças: como construir um artefato que produza recomendação e prova ao mesmo tempo, e cuja própria evidência de desempenho resista a auditoria hostil?

O objetivo é materializar e avaliar esse artefato para o contexto B2B de escritórios de investimento. O método segue a lógica de design science: identificar o problema, explicitar os requisitos, construir o artefato e avaliá-lo por utilidade, qualidade e capacidade de produzir evidência (Hevner et al., 2004; Peffers et al., 2007). A avaliação financeira não é uma demonstração comercial isolada. Ela executa, ano após ano, uma regra registrada antes do retorno seguinte, cobra custos, compara referências independentes e mede quanto a escolha

retrospectiva teria melhorado o resultado. A contribuição é dupla: um protocolo quantitativo auditável e um fluxo de trabalho capaz de transformar cada recomendação em documento verificável para revisão humana.

2. Fundamentação e posicionamento

Três problemas metodológicos bem documentados na literatura de finanças quantitativas foram tratados como requisitos de projeto, não como ressalvas de rodapé.

Viés de sobrevivência. Painéis montados a partir de provedores públicos de preço ajustado servem as empresas que ainda existem. Reconstruir o universo a partir de um provedor desses apaga silenciosamente toda empresa deslistada, adquirida ou liquidada, justamente as que produziram os piores retornos. O efeito é sistemático e sempre favorável ao backtest.

Informação disponível na data. Fundamentos precisam ser lidos como estavam no momento da decisão, com data de recebimento pelo regulador, não com a versão consolidada e eventualmente republicada. Chamar isso de detalhe é subestimar o problema: a diferença aparece com sinal previsível, sempre a favor de quem testa.

Múltiplas tentativas. Quando se avaliam dezenas de configurações e se publica a melhor, o índice de Sharpe observado é enviesado para cima pela própria busca. Bailey e López de Prado formalizaram o problema com o Sharpe deflacionado, que corrige a estatística pelo número de tentativas e pelos momentos superiores da distribuição de retornos. Sem essa correção, qualquer busca suficientemente ampla produz um vencedor aparentemente significativo.

Quatro referências clássicas orientam a construção financeira do artefato. Markowitz (1952) mostrou que uma carteira precisa ser analisada pela interação entre retornos e covariâncias, e não pela atratividade isolada de cada ativo. No Benevente, essa contribuição aparece de duas formas. A primeira é a exigência de uma cesta, em vez de uma aposta única no maior score. A segunda é o comparador MVO, que pergunta quanto uma alocação baseada apenas em média, covariância e limites teria produzido sobre o mesmo universo. O comparador não serve para validar automaticamente a estratégia; serve para impedir que um ganho atribuído ao filtro fundamental seja apenas efeito de diversificação quantitativa. A ênfase em qualidade também dialoga com Novy-Marx (2013), enquanto o uso conjunto de valor, qualidade e confirmação de mercado se aproxima da lógica multifatorial de Fama e French (2015), sem pretender reproduzir exatamente seus fatores.

Black e Litterman (1992) tratam da combinação entre equilíbrio de mercado e visões. A arquitetura do Benevente adota a separação conceitual, mas não implementa o modelo Black–

Litterman como carteira publicada. Fatos fundamentais e sinais de mercado geram um ranking determinístico. A linguagem natural pode explicar a visão, registrar riscos e formular perguntas, porém não altera a matemática da alocação. Essa fronteira permite testar a camada de linguagem sem conceder a ela poder para mudar restrições ou reconstruir retrospectivamente a tese.

DeMiguel, Garlappi e Uppal (2009) demonstram como erro de estimação pode eliminar, fora da amostra, a vantagem aparente de métodos sofisticados sobre uma diversificação simples. A resposta do projeto não é presumir que um otimizador sempre melhora o resultado. É publicar uma referência independente, impor um número mínimo de posições, limitar a interpretação das métricas e comparar decisões em sequência temporal. O resultado de 7,83% ao ano do MVO de referência nesta execução não prova que MVO é inferior em geral. Mostra somente que aquela implementação, com aquele universo elegível e aquelas estimativas disponíveis em cada janeiro, produziu esse caminho. Em outra amostra ou especificação, a ordem pode se inverter.

Novy-Marx e Velikov (2016) mostram que custos de negociação podem consumir anomalias documentadas. Por isso, o retorno usado na manchete já deduz taxas e deslizamento modelado, e a busca penaliza trocas de configuração. O sistema mede giro, participação no volume e realização tributável, em vez de tratar toda mudança de peso como gratuita. Ainda assim, uma estimativa não é uma nota de corretagem. O produto prevê conciliação posterior exatamente porque o custo observado depende do tamanho, do horário, da liquidez e da qualidade de execução de cada instituição.

Essas escolhas definem o tipo de evidência que o trabalho pode produzir. O backtest é um experimento histórico sobre um protocolo e não uma simulação da experiência individual de todo cliente. Suitability, necessidade de liquidez, tributação específica, ativos já detidos e restrições contratuais podem mudar a carteira implementável. Por isso, o artefato separa três objetos que costumam aparecer misturados: a regra acadêmica usada para medir o sinal; a política institucional que limita o risco; e o texto explicativo que ajuda uma pessoa a revisar a decisão. Uma boa curva não substitui nenhum dos três.

O posicionamento do artefato decorre desses três pontos. O Benevente não compete em promessa de retorno. Compete em verificabilidade. Qualquer concorrente exibe uma curva ascendente, e a pergunta que raramente é respondida é quanto daquela curva vem de ter escolhido a regra depois de ver o resultado. Este trabalho mede esse valor e o publica.

3. O artefato

3.1 Visão geral

O Benevente Wealth System é um sistema de apoio à decisão que executa um protocolo anual. Em janeiro, monta a carteira usando exclusivamente dados disponíveis naquela data. Mantém a carteira pelo ano, já com custos de execução. Revisa no ciclo seguinte. O resultado do ano entra depois, apenas para avaliação, e nunca retroalimenta a decisão que o gerou.

O sistema é composto por cinco camadas.

Tabela 1

Camadas do artefato e respectivas saídas auditáveis

Camada	Função	Saída auditável
Base de dados	Universo, preços e fundamentos com data	Manifesto com SHA-256 por arquivo
Elegibilidade	Tela de aprovação por ativo	Motivo de cada reprovação
Seleção e alocação	Escore multifatorial e regra quantitativa com limites	Ranking, pesos e restrições ativas
Execução	Ordens com lote e participação no volume	Custo estimado por ordem
Governança	Aprovação humana e conciliação	Quem aprovou e diferença contra a nota de corretagem

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

3.2 Base de dados: o universo de registro é a bolsa, não o provedor

O universo de registro é o arquivo histórico de cotações da própria B3, não um feed de terceiro. A consequência é direta e mensurável. O painel construído cobre 514 emissores entre 2010 e 2025, dos quais 166 deixam de negociar antes de dezembro de 2025, 77 deles antes de 2020, e 58 já haviam perdido mais de 60% do próprio topo quando pararam de negociar. Um painel montado a partir de provedor público simplesmente não contém essas empresas. A diferença entre incluí-las e não incluí-las é a diferença entre medir a estratégia e medir a sorte de ter olhado só para os sobreviventes.

Preços deslistados exigem tratamento de eventos societários sem a ajuda do provedor, que já não serve esses papéis. O sistema detecta desdobramentos, grupamentos e bonificações grandes a partir de razões de preço redondas e persistentes no arquivo da bolsa. O detector foi validado contra o arquivo de eventos de um provedor, no subconjunto de papéis em que esse arquivo

existe, e os dois lados da validação são publicados: precisão de 88,1%, com 340 de 386 ajustes aplicados coincidindo com um evento confirmado, e recall de 23,3%, com 103 de 443 eventos do provedor detectados. O recall baixo é uma limitação real e está declarada. O detector é conservador por construção, e prefere não ajustar a ajustar errado. Publicar apenas a precisão seria omitir metade do resultado.

Os fundamentos vêm dos formulários ITR e DFP da CVM, com a data de recebimento usada como porta: um documento só entra na decisão de janeiro do ano t se o regulador o recebeu antes daquela data. A ponte entre o ticker da B3 e o CNPJ da CVM é construída ano a ano, e sua cobertura é publicada em vez de suposta. Em 2012, primeiro ano da série, 266 de 314 ações tiveram ponte aceita e 171 tiveram fundamentos completos, porque a série do ITR começa em 2011 e 2012 é o primeiro ano em que a construção de doze meses tem os dois lados disponíveis.

3.3 Elegibilidade, seleção e alocação

A tela de elegibilidade reprova ativos por liquidez insuficiente, ausência de fundamento na data, alavancagem ou cobertura de juros fora do aceitável. Cada reprovação é registrada com o motivo, o que permite ao escritório responder por que um papel conhecido não entrou, pergunta que aparece com a mesma frequência da inversa.

O foco econômico é uma análise fundamentalista multifatorial. Qualidade procura empresas capazes de remunerar o capital e sustentar a operação; valor procura um preço coerente com lucros, patrimônio ou geração de caixa; momento de doze meses funciona como confirmação de mercado e reduz a compra mecânica de uma empresa barata que continua deteriorando. Liquidez determina se a tese é executável. Bancos e empresas operacionais recebem métricas diferentes porque dívida e margem operacional não significam a mesma coisa nos dois balanços. O retorno histórico entra como fator complementar, não substitui os demonstrativos.

Depois da triagem, cada ativo recebe um escore comparável dentro do universo disponível naquele janeiro. A estratégia publicada faz um corte nos melhores emissores, mantém apenas uma classe por emissor e distribui o orçamento de renda variável proporcionalmente ao escore, sujeito ao número de posições e aos limites da configuração. O saldo fica no CDI. A configuração completa — família de fatores, número de posições e orçamento de ações — é escolhida anualmente pelo desempenho ajustado ao risco nos anos já encerrados. A otimização média-variância não define essa carteira. Ela é calculada de modo independente, sobre o mesmo universo elegível, para medir o que uma carteira puramente quantitativa de média e covariância teria produzido.

Essa separação também resolve a ambiguidade entre os nomes. Benevente Quant AI designa a pesquisa acadêmica, inclusive o experimento que combina um modelo de linguagem com um solver convexo. Benevente Wealth System designa o produto B2B de governança que entrega proposta, explicação e registro. A carteira histórica publicada é a regra multifatorial determinística. O modelo de linguagem não seleciona ativo e não escreve peso; seu papel é transformar fatos aprovados em tese, riscos e perguntas para revisão humana.

O método é divulgado sem expor o código da aplicação comercial. No fator triplo, o escore é 0,40 vezes o escore padronizado da qualidade, 0,40 vezes o escore padronizado do inverso do preço/lucro e 0,20 vezes o escore padronizado do retorno dos 12 meses anteriores. Qualidade é ROIC para empresas operacionais e ROE para instituições financeiras. A triagem exige histórico de preço, liquidez média mínima, qualidade primária de pelo menos 8% e lucro positivo. Os candidatos alternativos são valor e qualidade por média de postos percentuais, momento de 12 meses e baixa volatilidade de 12 meses. A grade contém 36 combinações: orçamento de ações de 55%, 75% ou 95%; 5, 8 ou 12 emissores; e quatro famílias de sinal. O teto por emissor é o menor valor entre 25% e 1,6 vez a divisão uniforme do orçamento de ações pelo número de posições. Pesos do fator triplo são proporcionais ao escore deslocado para valores positivos e redistribuídos por preenchimento sucessivo quando um emissor atinge o teto. A configuração completa e a transformação de cada campo permanecem disponíveis nos artefatos legíveis por máquina, enquanto cada arquivo de entrada e saída recebe SHA-256. Assim, o estudo é replicável sem transformar a interface do produto em documentação de código.

3.4 Por que a decisão é anual

A cadência anual é uma hipótese coerente com a natureza do sinal e, neste estudo, uma escolha empiricamente testada. Qualidade, retorno sobre capital, alavancagem e geração de caixa são grandezas divulgadas em ciclos contábeis e cuja tese econômica precisa de tempo para aparecer no preço. Uma troca mensal baseada nelas pode vender uma empresa antes que a melhora operacional seja reconhecida e aumenta o número de decisões que precisam ser justificadas. A revisão em janeiro também cria uma fronteira operacional simples: tudo o que foi publicado até a data pode entrar; tudo o que veio depois pertence ao próximo ciclo.

Anual não significa que o sistema ignora o risco durante doze meses. Preços, concentração, liquidez e eventos materiais podem ser monitorados continuamente, e uma política institucional pode prever um gatilho extraordinário. Significa apenas que a reSeleção sistemática da cesta

acontece uma vez por ano. No teste de robustez, mantendo regra e dados constantes, a reSeleção anual superou as versões trimestral e mensal antes mesmo dos custos. Com apenas onze anos pareados, isso não prova que a frequência anual seja universalmente ótima; mostra que não houve evidência para substituir a regra mais simples nesta amostra.

Notícias não entram no modelo atual. Esse limite é intencional: um estudo com notícias exige arquivo histórico licenciado, horário de publicação, deduplicação e uma data de corte verificável para o modelo de linguagem. Misturar notícias retrospectivamente ao protocolo anual criaria uma nova oportunidade de usar informação futura. O estudo futuro adequado é um braço separado, pré-registrado, com revisão trimestral ou por evento e notícias carimbadas no tempo, comparado à regra anual sem alterar esta última.

3.5 Custos, imposto e execução

Retorno bruto não é resultado. O sistema modela três parcelas.

- Taxas da B3 e corretagem por ordem.
- Deslizamento por participação no volume, proporcional ao tamanho da ordem relativo ao volume médio diário do papel. Uma ordem grande em papel ilíquido custa mais, como custa na prática.
- Imposto de renda brasileiro, com 15% sobre ganho realizado em renda variável e 17,5% sobre renda fixa na faixa de 361 a 720 dias, cobrado no ano em que a revisão seguinte efetivamente realiza o ganho, e com liquidação integral assumida no último ano avaliado. Essa é a hipótese terminal conservadora, em vez de um diferimento indefinido que embelezaria a série.

O sistema recusa, por regra, ordens que ultrapassem 5% do volume médio diário do papel. A ordem falha em vez de ser enviada.

3.6 Governança: o sistema propõe, a pessoa decide

Quatro mecanismos delimitam o que o software pode fazer. Eles transformam a prestação de contas algorítmica em propriedade do desenho, e não em explicação produzida depois do fato (Kroll et al., 2017). A aprovação humana e o enquadramento ao perfil também são coerentes com a Resolução CVM nº 30, enquanto qualquer uso como consultoria individualizada depende da estrutura autorizada prevista na Resolução CVM nº 19 (Comissão de Valores Mobiliários, 2021a, 2021b).

1. Aprovação humana obrigatória. Nenhuma ordem é transmitida, nem pode ser, porque a

arquitetura não tem esse caminho.

2. Papel delimitado do modelo de linguagem. O modelo organiza tese e riscos a partir de fatos já aprovados. Ele não define peso, não altera limite e não aprova ativo. Isso é uma restrição de arquitetura verificável, não uma promessa de conduta, e a Seção 5.5 mostra o experimento que testou o que aconteceria se ela fosse relaxada.
3. Conciliação pós-operação. A nota de corretagem é confrontada linha a linha com a ordem proposta.
4. Limites explícitos e versionados. Teto de renda variável, teto por emissor e reserva em caixa ficam na política, registrados antes da seleção.

4. Método de avaliação

4.1 Seleção aninhada: a janela que escolhe não é a janela que testa

O artefato admite múltiplas configurações de política, combinando orçamento de renda variável, número de posições e família de fatores. Publicar a melhor delas medida sobre toda a amostra seria exatamente o erro que a Seção 2 descreve. O protocolo adotado é uma seleção aninhada: para decidir a configuração do ano t , o sistema ordena as 36 configurações usando somente os anos já encerrados antes de t , pelo índice de Sharpe do excesso sobre o CDI, e adota a primeira colocada. Trocar de configuração é uma operação real, e é cobrada como rebalanceamento integral.

O ranqueamento exige no mínimo três anos encerrados. Com o painel começando em 2012, isso torna 2012 a 2014 a janela de seleção e 2015 a 2025 a janela de avaliação, com onze decisões anuais, uma por ano. Os três anos de seleção aparecem nos gráficos, marcados como tal, e não entram em nenhuma métrica de manchete.

4.2 Comparadores

Quatro referências, todas calculadas de forma independente.

- CDI, série 12 do Banco Central, como custo de oportunidade do caixa.
- Ibovespa, índice de retorno total que incorpora os proventos da carteira teórica e, por isso, é comparável a uma carteira que os reinveste (B3, 2026b).
- BOVA11, ETF negociável que busca acompanhar o Ibovespa e permite observar uma implementação passiva sujeita a taxa, custos de negociação e diferença de aderência (BlackRock, 2026).

- Otimização média-variância neutra sobre o mesmo universo elegível, um comparador independente e não uma cópia da carteira com outro nome.

Esse último merece nota. Em uma versão anterior do sistema, a série rotulada como MVO de referência era numericamente idêntica à estratégia em todos os anos, ou seja, a estratégia estava sendo comparada a si mesma. O defeito foi encontrado na auditoria interna, corrigido com uma implementação independente, e o comparador passou a produzir resultados distintos, inclusive desfavoráveis à estratégia em um dos onze anos.

Ibovespa e BOVA11 não são duplicatas. O primeiro mede o retorno total de uma carteira teórica e estabelece a referência econômica do mercado. O segundo representa um caminho efetivamente negociável para buscar essa exposição. A pequena diferença entre as duas séries é informativa, pois reúne taxa, fricções operacionais e erro de aderência. Todos os comparadores usam as mesmas datas de início e fim da carteira.

4.3 Correção por múltiplas tentativas

Com 36 configurações avaliadas, o Sharpe da vencedora precisa ser deflacionado. Calculamos o Sharpe deflacionado com o número de tentativas, o número de observações e os momentos superiores da série de retornos.

Medimos também o prêmio de retrospectiva, que é a diferença entre o CAGR da configuração que teria vencido a amostra inteira, escolha impossível na prática porque usa os anos sobre os quais é medida, e o CAGR da escolha aninhada. Esse número quantifica exatamente o que um concorrente ganharia publicando o vencedor da busca como se fosse resultado obténível.

4.4 Benevente 2: proteção intranual sem trocar a tese anual

O Benevente 1 continua sendo a estratégia publicada: a cesta e o orçamento de risco são definidos na revisão anual e os ativos são mantidos até a revisão seguinte. O Benevente 2 é uma extensão experimental que não escolhe ações novas e não usa notícias. Ele observa somente a queda do Ibovespa em relação ao pico móvel de 126 sessões e a volatilidade realizada em 20 sessões, sempre deslocadas em um pregão. Assim, a decisão de hoje usa apenas o fechamento de ontem.

A configuração candidata foi escolhida somente em 2015--2018. Um alerta é acionado com queda de 12% ou volatilidade anualizada de 40%, limitando a exposição a ações a 50%. O estado severo usa 22% e 60%, respectivamente, e limita a exposição a 35%. A saída exige dez sessões de recuperação, para reduzir idas e vindas. O saldo migra para CDI e cada mudança

paga 0,10% por unidade de giro. O período de 2019--2025 é lido separadamente como avaliação retrospectiva. A extensão foi concebida depois da Covid-19, portanto essa separação temporal não elimina o viés conceitual e não equivale a validação prospectiva.

5. Resultados

5.1 Desempenho da carteira publicada

Onze decisões anuais, de 2015 a 2025, líquidas de custos de execução.

Tabela 2

Desempenho da carteira publicada e dos comparadores entre 2015 e 2025

Série	CAGR	R\$ 100 mil viram	Anos vencidos	Queda máxima diária
Benevente 1	17,86%	R\$ 609.832		-47,8%
Benevente, após IR	16,03%	R\$ 513.052		
Ibovespa	11,77%	R\$ 340.068	7 de 11	-47,0%
BOVA11 (ETF investível)	11,72%	R\$ 338.545	7 de 11	-47,2%
CDI	9,61%	R\$ 274.368	6 de 11	0%
MVO neutra, mesmo universo	7,83%	R\$ 229.255	10 de 11	

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

A coluna em reais existe porque percentual é fácil de aprovar com a cabeça e difícil de sentir. Cem mil reais aplicados em janeiro de 2015 e resgatados no fim de 2025 seriam R\$ 609.832 na carteira publicada, R\$ 340.068 no Ibovespa e R\$ 274.368 no CDI, uma diferença de R\$ 269.764 para o mercado e de R\$ 335.464 para o caixa.

Em janelas móveis, contra o CDI a carteira vence 8 de 9 janelas de três anos, 6 de 7 de cinco anos e 2 de 2 de dez anos. Contra a otimização neutra, vence todas as janelas de três, cinco e dez anos. Registramos que janelas móveis se sobrepõem: as 9 janelas de três anos contêm apenas 3 blocos independentes, e as de dez anos, apenas 1. O número de janelas vencidas impressiona mais do que informa, e por isso publicamos os dois lados.

Esse resultado teve um custo de risco. A queda máxima diária chegou a 47,8%, praticamente a mesma do Ibovespa, com 47,0%, e do BOVA11, com 47,2%. Isso ocorreu porque o protocolo aninhado elevou a parcela de renda variável a 95% entre 2018 e 2021. A carteira não é uma

versão suavizada do mercado com retorno maior. É uma carteira concentrada que passou pelo mesmo tombo e se recuperou mais. Houve cinco trocas de configuração no período, e o orçamento de renda variável percorreu 55%, 75%, 95%, 75% e 55%.

5.2 Benevente 2: o que melhorou e o que não foi provado

Tabela 3

Desempenho e risco do Benevente 1 e do Benevente 2

Série	CAGR 2015--2025	Queda máxima diária	CAGR 2019--2025
Benevente 1	17,86%	-47,8%	17,95%
Benevente 2, experimental	18,45%	-28,7%	18,03%

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Na crise de 2020, o primeiro alerta ocorreu em 28/02/2020 e o estado severo em 10/03/2020. A exposição mínima ficou em 35%. O Benevente 1 terminou o ano com 1,78%, o Benevente 2 com 4,35% e o Ibovespa com 0,62%. A queda máxima caiu de 47,8% para 28,7%, enquanto a do índice foi de 46,8%.

O resultado de retorno exige contenção. No recorte 2019--2025 a diferença de CAGR entre as versões foi de apenas 0,09 ponto percentual e o teste pareado anual produziu $p = 0,964$. Portanto, não há evidência de alfa adicional. Numa grade de sensibilidade com 432 configurações, todas reduziram a queda máxima, mas apenas 9,03% melhoraram simultaneamente CAGR e queda no recorte de avaliação. A conclusão sustentada é uma redução robusta de risco de cauda, não aumento comprovado de rentabilidade. Os números do Benevente 2 incluem custo de giro do controle intranual, mas ainda não o imposto gerado por vendas dentro do ano. Por isso ele permanece experimental e não substitui a série canônica.

5.3 O resultado sobrevive à correção por múltiplas tentativas?

Tabela 4

Estatísticas de correção por múltiplas tentativas

Estatística	Valor
Sharpe observado do excesso sobre o CDI	0,933
Sharpe máximo esperado sob a hipótese nula, com 36 tentativas	0,355
Probabilidade do Sharpe deflacionado	0,986
Significante a 95%	sim
Prêmio de retrospectiva	0,65 p.p. ao ano

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

O prêmio de retrospectiva merece leitura cuidadosa, porque é a medida mais informativa do conjunto. Ele diz que escolher a configuração vencedora sabendo o desfecho teria rendido apenas 0,65 ponto percentual a mais por ano do que a escolha aninhada, que não sabia. Em uma versão anterior deste mesmo sistema, com um ano a menos de treino, esse prêmio era de 4,98 pontos, ou seja, a busca estava fazendo boa parte do trabalho. Estender a base de dados para permitir decisões desde 2012 reduziu o prêmio por um fator de sete e elevou a probabilidade do Sharpe deflacionado de 0,957 para 0,986. O ganho relevante da última iteração do artefato não foi retorno. Foi a redução da parcela do retorno atribuível à própria busca.

5.4 O que não funcionou

Quatro hipóteses foram testadas e nenhuma se sustentou. São publicadas com o mesmo destaque do resultado positivo, porque um artefato que só reporta o que deu certo não é auditável.

Previsão anual de regime. Testamos se indicadores disponíveis em janeiro, entre prêmio de lucro sobre o CDI, nível do CDI, retorno e volatilidade do mercado nos doze meses anteriores e distância do topo, anteciparam se o ano seria de ações ou de caixa. Sobre 8 anos, o melhor preditor acertou 3 de 4 chamadas efetivas, com p de 0,31 contra cara-ou-coroa. Um acerto de 75% em quatro tentativas não distingue habilidade de sorte. O prêmio disponível para quem acertasse todas as chamadas era de 6,5 pontos percentuais ao ano, e permanece inalcançável. Sem sinal.

Realocação mensal e semanal. Aumentamos as observações para responder à objeção de poder estatístico. Foram 118 períodos mensais e 521 períodos semanais, com sete regras de alocação

continua testadas em cada frequência. Nenhuma das sete regras superou o peso estático de forma estatisticamente significativa em nenhuma das duas frequências, e uma delas, a de média-variância, foi significativamente pior. O oráculo, que conhece o futuro, teria feito 72,8% ao ano no mensal e 137,1% no semanal, contra 21,1% do estático. O prêmio por acertar o tempo é enorme, e nada que testamos consegue capturá-lo. Rejeitada.

Reseleção mais frequente da cesta. A objeção seguinte é diferente da anterior e precisa ser separada dela: não se a proporção entre ações e caixa deve mudar mais vezes, que é o que o parágrafo acima rejeita, mas se a própria cesta deveria ser retriada, reordenada e reotimizada mais vezes por ano. Testamos três cadências com a mesma regra, os mesmos limites e o mesmo painel, variando apenas as datas de decisão.

Tabela 5

Desempenho por cadência de reseleção da carteira

Cadência	Decisões	CAGR bruto	Líquido de custo	Após IR	Giro no ano
Anual	11	18,58%	18,51%	17,09%	62,1%
Trimestral	44	16,37%	16,25%	15,60%	116,0%
Mensal	132	13,92%	13,75%	13,32%	177,6%

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Nenhuma cadência mais rápida superou a anual. Pareando por ano-calendário, a trimestral fica 1,55 ponto percentual abaixo ao ano após imposto, com p de 0,376, e a mensal 3,27 pontos abaixo, com p de 0,306. A leitura correta é que não há evidência de que decidir mais vezes ajude, e não que esteja provado que atrapalhe: onze anos pareados não sustentam a afirmação mais forte.

O mecanismo contraria a intuição corrente, que atribuiria a diferença a custo e imposto. A perda está no retorno bruto, que cai 4,66 pontos de anual para mensal antes de qualquer dedução. O custo de execução sobe apenas 0,08 ponto ao ano, e o imposto modelado até diminui, porque cada revisão mensal realiza uma fatia menor do livro. Ou seja, decidir mais vezes piora a seleção antes de encarecer a operação. O sinal combina qualidade, valor e momento, grandezas que se movem em horizonte anual, e reordenar todo mês troca posições antes que a tese tenha tempo de se realizar.

Registramos uma fraqueza do modelo tributário nessa comparação: ele cobra imposto sobre o ganho do próprio período, e não sobre o ganho acumulado da posição efetivamente vendida, o que subestima a conta do braço mensal. O viés favorece a cadência mais rápida, e ela perdeu

mesmo assim, então a conclusão é robusta a essa limitação.

Modelo de linguagem como fonte de retorno. Este é o teste que mais interessa à governança do produto, e está detalhado a seguir.

5.5 O experimento com modelo de linguagem: três nulos

O sistema usa um modelo de linguagem em papel deliberadamente restrito. Para verificar se essa restrição custa desempenho, e se o modelo agrega algo, montamos quatro braços sobre 13 anos, com o mesmo universo elegível.

- Nomeado: o modelo vê os nomes das empresas e devolve um escore limitado, que inclina o retorno esperado dentro do otimizador convexo.
- Anonimizado: idêntico, mas as empresas são identificadas apenas por números, de modo que o modelo vê os fundamentos e não as marcas.
- Determinístico: controle sem modelo algum, ordenando o mesmo universo pelo escore de fator pré-declarado.
- Monolítico: o contrafactual em que o modelo devolve pesos diretamente, sem otimizador e sem restrições.

Tabela 6
Comparações do experimento com modelo de linguagem

Comparação	Diferença anualizada	p
Nomeado menos anonimizado (contaminação temporal)	+0,38 p.p.	0,905
Anonimizado menos determinístico (valor agregado pelo modelo)	−0,05 p.p.	0,989
Anonimizado menos monolítico (valor do desacoplamento)	+0,81 p.p.	0,777

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Três nulos, e cada um significa algo diferente.

1. Não há evidência de contaminação temporal. O braço nomeado não lucrou por reconhecer empresas cujo destino o modelo poderia conhecer do treinamento. Essa era a objeção mais séria a qualquer uso de modelo de linguagem em backtest histórico, e ela não se sustentou nesta configuração.
2. O modelo não agrega retorno. Ele reproduz o ranqueamento determinístico em vez de

acrescentar julgamento, com diferença de cinco centésimos de ponto percentual e sinal negativo. Isso é uma constatação desconfortável para o discurso de mercado sobre IA em investimentos, e é exatamente por isso que está publicada.

3. O desacoplamento não custa desempenho. Manter o modelo longe dos pesos não penalizou o resultado, e se algo o braço desacoplado foi melhor. O braço monolítico, que recebeu a caneta, não estourou nenhum teto, o que é uma constatação a favor dele e precisa ser dita. O que ele produziu foram carteiras aritmeticamente inválidas: os pesos não somavam um em 5 dos 13 anos, variando de 0,92 a 1,017, e em 2021 e 2022 omitiu 65 e 83 ativos elegíveis sem sinalizar. O otimizador não se justifica por impedir violação de limite, e sim por devolver uma alocação válida que não precise de conserto depois.

A conclusão de produto é direta. O modelo de linguagem justifica-se no Benevente por organizar e explicar decisões, não por gerá-las. Vender IA como fonte de alfa, com base nestes dados, seria vender algo que medimos e não encontramos.

5.6 Defeitos encontrados na própria auditoria

O artefato passou por auditoria interna adversarial. Sete defeitos foram encontrados e corrigidos, e todos inflavam o resultado.

Tabela 7

Defeitos identificados na auditoria interna e respectivas correções

Defeito	Efeito	Correção
Comparador MVO idêntico à estratégia	Comparação da estratégia consigo mesma	Implementação independente
Painel de provedor descartava deslistadas	Viés de sobrevivência	Universo reconstruído do arquivo da B3
Ano de deslistagem descartado inteiro	Perda truncava o ano	Liquidação da posição em CDI
Imposto ausente	Retorno superestimado	Modelo tributário brasileiro
Custo fixo ignorando liquidez	Ordem grande sem penalidade	Deslizamento por participação no volume
Rebalanceamento diário implícito	Artefato de vetorização	Trajetória de compra e manutenção
Filtro de sessões usando pico global	Anos legítimos descartados	Pico móvel local

Nota. Elaboração própria com base nos artefatos reproduzíveis da pesquisa.

Depois da última correção, o CAGR publicado caiu, a queda máxima subiu de 30,4% para 47,8%, e o número foi publicado assim mesmo. Essa é a evidência de processo que o produto

vende: não que o resultado seja bom, mas que ele é o resultado que sobrou depois de procurar defeitos com afinco.

6. Contribuição tecnológica e aderência ao mercado

O fluxo de uso foi desenhado para que cada tela responda à pergunta criada pela anterior. Primeiro, a instituição escolhe a política e aceita os limites. Segundo, o sistema mostra quais arquivos e demonstrações estavam disponíveis e quais passaram na validação. Terceiro, a triagem informa ativos aprovados e reprovados com motivos. Quarto, a carteira candidata apresenta pesos, parcela em CDI, custo e comparação com as referências. Quinto, a pessoa revisa a tese em linguagem natural, aprova ou rejeita e registra a justificativa. Por fim, o dossiê reúne a decisão inteira, inclusive a versão da regra e os hashes dos arquivos. O usuário não precisa alternar entre um laboratório técnico e um documento separado; a experiência e a prova são duas visões do mesmo registro.

Para o escritório. O sistema entrega, por decisão, um dossiê completo, com política aplicada, dados com data e hash, tela de elegibilidade com motivo de cada reprovação, pesos, ordens com lote e participação no volume, e custo estimado. O que antes era reconstruído a mão sob pressão passa a ser subproduto da própria operação.

Para o cliente final. A pergunta "por que este papel?" passa a ter resposta datada e verificável, e a pergunta simétrica, "por que não aquele?", também.

Para o ecossistema capixaba. A hipótese comercial não é “rendemos mais”. É que um escritório local com processo demonstrável pode reter uma parcela maior do trabalho analítico e do relacionamento de longo prazo no estado. Essa hipótese precisa ser testada em entrevistas e pilotos; o backtest não a comprova.

Modelo de oferta a validar. A primeira versão comercial pode ser licenciada por instituição, com cobrança por usuários e número de políticas acompanhadas, e um serviço de implantação para integrar fontes, identidade, aprovação e arquivo documental. Não há preço publicado nem receita comprovada. As métricas do piloto devem ser tempo para produzir um dossiê, percentual de decisões com evidência completa, divergência entre custo previsto e nota conciliada, número de revisões exigidas e disposição a pagar. Retorno da carteira permanece uma medida de pesquisa e acompanhamento, nunca base de remuneração ou garantia contratual.

Maturidade. O artefato está em estágio de pesquisa reproduzível, não de produto validado institucionalmente. A janela de 2015 a 2025 foi usada para desenvolver e escolher a regra, e portanto descreve a amostra e não prevê o futuro. A avaliação prospectiva começa a partir do

registro congelado, cujo hash está versionado no repositório com data carimbada por terceiro. Um registro pré-especificado que exista apenas no disco de quem o escreveu não demonstra anterioridade nenhuma.

7. Limitações

Declaradas sem atenuação, porque uma limitação omitida vira defeito descoberto pelo avaliador.

1. A janela avaliada é a janela de desenvolvimento. Onze anos avaliados não são onze anos de validação prospectiva. O prêmio de retrospectiva de 0,65 p.p. limita o problema, mas não o elimina.
2. O detector de eventos societários tem recall de 23,3%. Ele é conservador, e proventos, juros sobre capital próprio e eventos de papéis deslistados ainda exigem reconciliação contra registro primário da B3 ou da CVM antes de qualquer afirmação comercial de desempenho.
3. Distribuições imputadas. Papéis sem cobertura de provedor recebem o rendimento mediano da seção transversal do ano. É uma aproximação, e os papéis afetados estão listados no relatório de cobertura.
4. A queda máxima é grande. Quase 48% em base diária. Nenhuma suitability razoável coloca um cliente conservador nessa carteira.
5. Onze observações anuais são poucas. A probabilidade do Sharpe deflacionado corrige o viés de busca, não o tamanho da amostra.
6. Uso comercial exige estrutura regulatória própria. O sistema é apoio à decisão e trilha de auditoria. Não é recomendação individual, gestão discricionária, nem promessa de superar referências.
7. O Benevente 2 é retrospectivo e posterior à Covid-19. A escolha em 2015--2018 e a leitura separada de 2019--2025 evitam usar o retorno futuro na conta diária, mas não removem o conhecimento humano de que uma crise sanitária ocorreu.
8. O imposto intranual do Benevente 2 ainda não foi reconciliado. Custos de giro foram cobrados, mas vendas defensivas podem antecipar imposto e reduzir o resultado líquido.
9. Não existe arquivo histórico de notícias com horário validado neste experimento. O controle usa apenas preço e volatilidade. A LLM não antecipou a Covid-19 e não tomou decisões no Benevente 2.

8. Agenda

- Acumular anos avaliados depois do registro congelado, que é a única evidência capaz de mudar o estatuto do artefato de pesquisa para validado.
- Reconciliar eventos societários e proventos contra registro primário, elevando o recall do detector.
- Repetir o experimento de contaminação em modelos com datas de corte de treinamento distintas, para separar contaminação de capacidade.
- Pré-registrar um estudo trimestral ou orientado a eventos, com notícias arquivadas, horário de publicação e corte temporal verificável, sem reotimizar a regra anual depois de observar o resultado.
- Pré-registrar o Benevente 2 antes de qualquer acompanhamento futuro, incorporar imposto por lote vendido e comparar seus estados discretos a um alvo contínuo de volatilidade escolhido somente na janela de treino.
- Instrumentar o piloto em escritório capixaba, medindo tempo de produção do dossiê e taxa de divergência na conciliação de notas.

9. Disponibilidade

A versão submetida inclui um pacote suplementar anônimo com o código de reprodução, os artefatos de avaliação e o manifesto criptográfico. Os endereços públicos do sistema e do repositório foram omitidos para preservar a avaliação cega. Após o aceite, a versão de câmera deverá restaurar esses endereços e indicar o arquivo permanente com DOI.

Referências

- Bailey, D. H., Borwein, J. M., López de Prado, M., & Zhu, Q. J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69. <https://doi.org/10.21314/JCF.2016.322>
- Bailey, D. H., & López de Prado, M. (2014). The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality. *Journal of Portfolio Management*, 40(5), 94–107. <https://doi.org/10.3905/jpm.2014.40.5.094>
- Banco Central do Brasil. (2026). *Sistema Gerenciador de Séries Temporais: série 12, taxa de juros CDI*. <https://www3.bcb.gov.br/sgspub/>
- B3 S.A. – Brasil, Bolsa, Balcão. (2026a). *Cotações históricas: série histórica de preços dos*

títulos negociados na Bolsa.

https://www.b3.com.br/pt_br/market-data-e-indices/servicos-de-dados/market-data/historico/mercado-a-vista/cotacoes-historicas/

B3 S.A. – Brasil, Bolsa, Balcão. (2026b). *Ibovespa B3*. https://www.b3.com.br/pt_br/market-data-e-indices/indices/indices-amplos/ibovespa.htm

Benevente Wealth System. (2026). *Documentação técnica, repositório de dados e validação de horizontes*. Repositório anônimo de avaliação.

Black, F., & Litterman, R. (1992). Global portfolio optimization. *Financial Analysts Journal*, 48(5), 28–43. <https://doi.org/10.2469/faj.v48.n5.28>

BlackRock. (2026). *iShares Ibovespa Fundo de Índice (BOVA11): factsheet*.

<https://www.blackrock.com/br/literature/fact-sheet/bova11-ishares-ibovespa-fundo-de-ndice-fund-fact-sheet-pt-lm.pdf>

Comissão de Valores Mobiliários. (2021a). *Resolução CVM nº 19, de 25 de fevereiro de 2021: atividade de consultoria de valores mobiliários* (texto consolidado).

<https://conteudo.cvm.gov.br/legislacao/resolucoes/resol019.html>

Comissão de Valores Mobiliários. (2021b). *Resolução CVM nº 30, de 11 de maio de 2021: adequação dos produtos, serviços e operações ao perfil do cliente* (texto consolidado).

<https://conteudo.cvm.gov.br/legislacao/resolucoes/resol030.html>

Comissão de Valores Mobiliários. (2026a). *Demonstrações Financeiras Padronizadas (DFP): dados abertos*. https://dados.cvm.gov.br/dataset/cia_aberta-doc-dfp

Comissão de Valores Mobiliários. (2026b). *Formulário de Informações Trimestrais (ITR): dados abertos*. https://dados.cvm.gov.br/dados/CIA_ABERTA/DOC/ITR/DADOS/

DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *Review of Financial Studies*, 22(5), 1915–1953. <https://doi.org/10.1093/rfs/hhm075>

Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22. <https://doi.org/10.1016/j.jfineco.2014.10.010>

Harvey, C. R., Liu, Y., & Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68. <https://doi.org/10.1093/rfs/hhv059>

Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information

systems research. *MIS Quarterly*, 28(1), 75–105. <https://doi.org/10.2307/25148625>

Kroll, J. A., Huey, J., Barocas, S., Felten, E. W., Reidenberg, J. R., Robinson, D. G., & Yu, H. (2017). Accountable algorithms. *University of Pennsylvania Law Review*, 165(3), 633–705.

López de Prado, M. (2018). *Advances in financial machine learning*. Wiley.

Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
<https://doi.org/10.2307/2975974>

Novy-Marx, R. (2013). The other side of value: The gross profitability premium. *Journal of Financial Economics*, 108(1), 1–28. <https://doi.org/10.1016/j.jfineco.2013.01.003>

Novy-Marx, R., & Velikov, M. (2016). A taxonomy of anomalies and their trading costs. *Review of Financial Studies*, 29(1), 104–147. <https://doi.org/10.1093/rfs/hhv063>

Peppers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45–77. <https://doi.org/10.2753/MIS0742-1222240302>